

k-mer解析とゲノムサイズ推定

k-mer analysis and genome size estimation


Shuji Shigenobu

NIBB, Japan

<shige@nibb.ac.jp>

Whole genome shotgun sequencing

Genome DNA
Very long!




ゲノムサイズ推定の重要性と手法

- ▶ ゲノムサイズは、シーケンスやアセンブリ戦略を立てるための「基礎情報」である。
- ▶ 実験的手法: Feulgen染色(デンストメトリー)、DNA蛍光染色(フローサイトメトリー)。
- ▶ 計算的手法: k-mer解析。比較的容易に推定でき、ゲノム構造(反復配列など)も把握可能。


k-merとは？

- ▶ 定義：長さ k の塩基配列断片。
- ▶ 任意の長さ L の配列から得られるk-merの個数は $L - k + 1$ 個




なぜk-merからサイズが推定できるのか？


- ▶ リード中のk-mer出現頻度分布は、ゲノムの構造的特徴を反映する。
- ▶ 理想的な条件下では、ユニークなk-merは平均して一定の頻度 (coverage) で観測される。
- ▶ **基本概念:**「k-mer頻度分布 (k-merスペクトラム) から“代表的な深度”を見積もり、総k-mer量と対応づける」。



1. Sequencing reads




2. k-mer decomposition (k=5)



3. k-mer counting



4. k-mer spectrum



genome
size
estimation

最適なkの長さの選択

- ▶ 目標: ゲノム中のほとんどのk-merがユニークになるようにする。
- ▶ ユニークである確率 $p < 0.01$ を満たす条件:
 $k > \log_4(200G)$ 。
- ▶ 実務上の目安: 19~25 bpが一般的。
- ▶ トレードオフ: 短すぎるとエラーや反復配列に紛れる。長すぎるとメモリ消費増大や低カバレッジでの欠落が生じる。

ゲノムサイズ推定の数理モデル（理想時）

- ▶ ゲノムサイズ G の推定式:

$$G = \frac{N(L - k + 1)}{C_k p}$$

- ▶ N : リード数、 L : 平均リード長、 k : k -mer長。 C_k : 平均 k -merカバレッジ。 p : 倍数性 (ploidy)。
- ▶ C_k は k -mer スペクトラムのピーク位置から読み取る

ゲノムサイズ推定の数理モデル（理想時）

▶ ゲノムサイズ G の推定式:

$$G = \frac{N(L - k + 1)}{C_k p}$$

▶ N : リード数、 L : 平均リード長、 k : k -mer長。 C_k : 平均 k -merカバーレッジ。 p : 倍数性 (ploidy)。


▶ (例) リード100 bp のショートリードを1,000万本 ($N = 10$ M reads) 取得し、 $k = 21$ で k -merスペクトラムを作成したところ、 k -mer coverage = 20 にピークが観察された。

$$G = \frac{10,000,000 \times (100 - 21 + 1)}{20 \times 2} = 2.0 \times 10^7 \text{bp}$$

現実的なk-merスペクトラム

- ▶ 理想的な条件下ではk-mer の出現頻度はポアソン分布に近づく
 - ▶ 現実：
 - ▶ シーケンスエラー
 - ▶ リピート配列
 - ▶ ヘテロ接合性
- ⇒ 複雑なk-merスペクトラム

現実的なk-merスペクトラム



解析の実際 1

- ▶ Step 1: Count k-mer

- ▶ Tool: Jellyfish

```
$ jellyfish count -t 4 -m 21 -C -s 2G -o reads.k21.jf  
DRR463117.fastq  
$ jellyfish histo -t 4 -h 100000000 reads.k21.jf >  
reads.k21.hist
```

- ▶ Step 2: ヒストグラムの描画

- ▶ R等

- ▶ Step 3: ピークの読み取りと理論式へのあてはめ

解析の実際 1


- ▶ ex201: k-mer解析とゲノムサイズ推定 I
 - ▶ 前半

より正確な推定 : GenomeScope

- ▶ スペクトラムに含まれる各成分(エラー由来、ヘテロ接合、ホモ接合、反復配列など)を統計モデルでフィッティングする手法が有効。
- ▶ 代表的ツール : GenomeScope
- ▶ 原理 : 観測されたk-merスペクトラムに対して負の二項分布の混合モデルを当てはめ、ゲノムサイズ、反復配列の割合、ヘテロ接合率などの複数の指標を同時に推定する。

Genome Scope

a



解析の実際2: GenomeScope2

▶ Step 1: Count k-mer

▶ Tool: Jellyfish

```
$ jellyfish count -t 4 -m 21 -C -s 2G -o reads.k21.jf  
DRR463117.fastq  
$ jellyfish histo -t 4 -h 100000000 reads.k21.jf >  
reads.k21.hist
```

▶ Step 2: GenomeScopeの実行

```
$ genomescope2 -i reads.k21.hist -o gsscope2_result -k 21 -  
p 2
```


解析の実際 1

- ▶ ex201: k-mer解析とゲノムサイズ推定 I
 - ▶ 後半

まとめ：k-mer解析が提供する知見

- ▶ 比較的正確にゲノムサイズ推定できる
- ▶ サイズ推定を超えた活用
 - ▶ ゲノム特性（ヘテロ接合性、反復配列量、エラー率）の総合的把握。
 - ▶ アセンブリ品質の評価やトラブルシューティング（Merquryなど）。
 - ▶ k-mer 自体がde Bruijnグラフに基づくアセンブリなど、ゲノムインフォマティクスの多くの場面で中心的な概念

演習

- ▶ ex202: k-mer解析とゲノムサイズ推定 2