

基礎生物学研究所

ゲノムインフォマティクス・トレーニングコース2026年3月

ゲノムのアセンブル

Genome assembly


Shuji Shigenobu

NIBB, Japan

<shige@nibb.ac.jp>

Whole genome shotgun sequencing

Genome DNA
Very long!




Genome assembly

- ▶ **Definition** — In whole-genome shotgun sequencing, **assembly** refers to the process of stitching together the large number of short reads generated by the sequencer.
- ▶ Like solving a jigsaw puzzle: overlaps between reads are detected by sequence comparison, and these overlaps are used to reconstruct the original genome.
- ▶ A contiguous reconstructed DNA segment is called a **contig**.
- ▶ Connecting contigs into longer structures is called scaffolding, and the resulting sequences are **scaffolds**.
- ▶ Assembly requires sophisticated algorithms and substantial computational resources.

アセンブル


- ▶ 全ゲノムショットガンシーケンス法において、シーケンサーから得られた多数のリードを繋げていく作業を「アセンブル」と呼ぶ。
- ▶ ジグソーパズルのように、リードどうしの重なり具合を配列比較することによって調べてリードを並べて元のゲノム配列を構築する。
- ▶ アセンブルによって得られる一続きのDNA断片の塩基配列を「コンティグ (contig)」と呼ぶ。
- ▶ コンティグをさらにつなげることを「スキヤフォールディング」と呼び、得られた配列をスキヤフォールド(scaffold)と呼ぶ
- ▶ アセンブルには高度なアルゴリズムと膨大な計算が必要。

コンティグとスキヤフォルド



Adams, J. (2008) Nature Education

コンティグとスキヤフォルド



Adams, J. (2008) Nature Education

Contig: a set of overlapping (*contiguous*) DNA segments that together represent a consensus region of DNA. No gaps included.

Scaffold: multiple contigs are connected by gaps which represented as many NNN... in most cases. Mate-pair and long-read information are used for scaffolding.

Simple example of genome assembly

- ▶ input: 10 reads (400 bp each)
- ▶ tool: cap3

```

consensus      GTGACGCAACTGGATAGACAGATCGAATTCTACCCATAAAGCCATCAA
               .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .
seq05+         CAACCCTTGGTTGAATAGTCTTGATTATGGAATTTAAGGGAAATACAA
seq04-         CAACCCTTGGTTGAATAGTCTTGATTATGGAATTTAAGGGAAATACAAAATTTGGACATT

               CAACCCTTGGTTGAATAGTCTTGATTATGGAATTTAAGGGAAATACAAAATTTGGACATT
               .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .
seq05+         CCCCATTGAAGGTGTCAAATTTCTTTGCCAATTTAATTTCAAAGGTGTCTGCAATTCAT
seq04-         CCCCATTGAAGGTGTCAAATTTCTTTGCCAATTTAATTTCAAAGGTGTCTGCAATTCAT
seq06+         CCCCATTGAAGGTGTCAAATTTCTTTGCCAATTTAATTTCAAAGGTGTCTGCAATTCAT
consensus      CCCCATTGAAGGTGTCAAATTTCTTTGCCAATTTAATTTCAAAGGTGTCTGCAATTCAT

               .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .
seq05+         AGCTCTTTTCAGAACGTTCCGTGTACCAAGCAATTTTCATG
seq04-         AGCTCTTTTCAGAACGTTCCGTGTACCAAGCAATTTTCATGCTCATGTTTCACGGCAGCAGT
seq06+         AGCTCTTTTCAGAACGTTCCGTGTACCAAGCAATTTTCATGCTCATGTTTCACGGCAGCAGT
consensus      AGCTCTTTTCAGAACGTTCCGTGTACCAAGCAATTTTCATGCTCATGTTTCACGGCAGCAGT

               .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .
seq04-         ATACACCCCTCTTAGTGTCAATAAAGTCCAGTTGTTTCGGACAAAGTGCATGAAGCTTTAC
seq06+         ATACACCCCTCTTAGTGTCAATAAAGTCCAGTTGTTTCGGACAAAGTGCATGAAGCTTTAC
seq03-         GAAGCTTTAC

consensus      ATACACCCCTCTTAGTGTCAATAAAGTCCAGTTGTTTCGGACAAAGTGCATGAAGCTTTAC

               .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .
seq04-         CAGCACGTGCTAGAAGGTCTTTAATGCACTCAAGAGGGTAGCCATCAGGGCCACAGAAGT
seq06+         CAGCACGTGCTAGAAGGTCTTTAATGCACTCAAGAGGGTAGCCATCAGGGCCACAGAAGT
seq03-         CAGCACGTGCTAGAAGGTCTTTAATGCACTCAAGAGGGTAGCCATCAGGGCCACAGAAGT
consensus      CAGCACGTGCTAGAAGGTCTTTAATGCACTCAAGAGGGTAGCCATCAGGGCCACAGAAGT

               .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .
seq04-         TGTTATCGACATAGCGAGTGTATGCCCTCCGTTAAGCTCACGCATGAGTTCACGGGTAA
seq06+         TGTTATCGACATAGCGAGTGTATGCCCTCCGTTAAGCTCACGCATGAGTTCACGGGTAA
seq03-         TGTTATCGACATAGCGAGTGTATGCCCTCCGTTAAGCTCACGCATGAGTTCACGGGTAA
consensus      TGTTATCGACATAGCGAGTGTATGCCCTCCGTTAAGCTCACGCATGAGTTCACGGGTAA

               .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .
seq04-         CACCACTGCTATGTTTAGTG
seq06+         CACCACTGCTATGTTTAGTGTTCCAGTTTTCTTGAAAATCTTCATAAGGATCAGTGCCAA
seq03-         CACCACTGCTATGTTTAGTGTTCCAGTTTTCTTGAAAATCTTCATAAGGATCAGTGCCAA
seq07+         TCAGTGCCAA

consensus      CACCACTGCTATGTTTAGTGTTCCAGTTTTCTTGAAAATCTTCATAAGGATCAGTGCCAA

               .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .   .
seq06+         GCTCGTCGCCTAAGTCAAATGACTTTTAGATCGGCGCCGTA
seq03-         GCTCGTCGCCTAAGTCAAATGACTTTTAGATCGGCGCCGTAAGTATGGCCACCAGTCTCTT
seq07+         GCTCGTCGCCTAAGTCAAATGACTTTTAGATCGGCGCCGTAAGTATGGCCACCAGTCTCTT
seq08+         ACTATGGCCACCAGTCTCTT



```

Genome Assembly in detail in practice

- ▶ In real genome assembly, we typically use millions of sequencing reads as input to construct contigs.
 - ▶ => This process is computationally intensive and time-consuming.
 - ▶ => Therefore, efficient algorithms are essential.
- ▶ Real sequencing reads inevitably contain errors.
 - ▶ => Error-tolerant strategies are required.
 - ▶ => These strategies further increase computational complexity.

アセンブルの理論的背景


ジグソーパズル




Two approaches for genome assembly

Overlap-Layout-Consensus (OLC)

(i) Find overlaps



(ii) Layout reads



(iii) Build consensus

```


CGATTCTA
  TTCTAAGT
  GATTGTAA
  -----
CGATTCTAAGT
    
```

de Bruij graph (DBG)


(i) Make kmers

Read1: TTCTAAGT	Read2: CGATTCTA	Read3: GATTGTAA
Kmers: TTC	Kmers: CGA	Kmers: GAT
TCT	GAT	ATT
CTA	ATT	TTG
TAA	TTC	TGT
AAG	TCT	GTA
AGT	CTA	TAA

(ii) Build graph




(iii) Walk graph and output contigs



Overlap-Layout-Consensus (OLC)

▶ 3 steps


- ▶ (i) **Overlap**: overlaps are found between reads and an overlap graph constructed.




- ▶ (ii) **Layout**: Reads are laid out into contigs based on the overlaps.
 - ▶ Problems is formulated as *Shortest common superstring* problem
- ▶ (iii) **Consensus**: The most likely sequence is chosen to construct consensus sequence.
 - ▶ Local multiple alignment and get consensus

- ▶ Originally developed for Sanger sequencing. Not feasible for Illumina reads due to the high computational demand.

(i) Find overlaps



(ii) Layout reads



(iii) Build consensus

```
CGATTCTA
  TTCTAAGT
  GATTGTAA
  CGATTCTAAGT
```

de Bruij graph (DBG)


3 steps

- ▶ (i) Reads are decomposed into kmers by sliding a window of size k across the reads.
- ▶ (ii) The kmers become vertices in the dBg, with edges connecting overlapping kmers. Polymorphisms (red) form branches in the graph. A count is kept of how many times a kmer is seen, shown here as numbers above kmers.
- ▶ (iii) Contigs are built by walking the graph from edge nodes. A variety of heuristics handle branches in the graphs—for example, low coverage paths, as shown here, may be ignored.


(i) Make kmers

Read1: TTCTAAGT	Read2: CGATTCTA	Read3: GATTCTAA
Kmers: TTC	Kmers: CGA	Kmers: GAT
TCT	GAT	ATT
CTA	ATT	TTG
TAA	TTC	TGT
AAG	TCT	GTA
AGT	CTA	TAA

(ii) Build graph



(iii) Walk graph and output contigs



- ▶ Constructed de Bruij graph is Euler cycle and Hamiltonian cycle. Assembly problem is formulated as Chinese postman problem and Travelling salesman problem.
- ▶ Computational much lighter than OLC and feasible for large data of illumine short reads.


Repeats makes assembly difficult

Collapsing a tandem repeat:

a_long_long_long_time



a_long_long_time




Repeats makes assembly difficult

1000ピース



108ピース



- ▶ Using long reads is the most effective solution for repeat problems
- ▶ HiFi long reads are preferred

アセンブルの実際

Hifiasm : HiFi read 向け ゲノムアセンブラ

▶ HiFiリードへの最適化

- ▶ PacBio HiFiロングリード(精度 >99%、長さ 10–25 kb)専用設計
- ▶ 高精度と十分な長さを活用し、「高い連続性(Contiguity)」と「塩基精度」を両立

▶ 幅広い適用範囲

- ▶ 細菌などの小規模ゲノムから、ヒト・植物などの複雑な大規模ゲノムまで対応

▶ ハプロタイプ分解(Haplotype-resolved Assembly)

- ▶ 標準機能として二倍体ゲノムのハプロタイプを分離
- ▶ 出力: primary (主要なアセンブリ)に加え、hap1 / hap2 を出力
- ▶ 前提: 単一個体由来のリード入力

Hifiasm の性能と実用性

▶ 高い連続性

- ▶ 動植物ゲノムにおいて N50 数Mbp以上 が期待可能
- ▶ 小規模ゲノムでは追加のスキュフォルディングなしで染色体レベルに到達することも

▶ リピート解決能力

- ▶ テロメアを含む高コピーリピート領域の解決に優れる

▶ 実務上のメリット

- ▶ 現在のゲノム解析におけるデファクトスタンダード(大型プロジェクトでの採用実績)
- ▶ 染色体レベルには至らずとも、実用上極めて高いクオリティのアセンブリを迅速に得られる


Hifiasm のアルゴリズム : String Graph 法

- ▶ String Graph (OLC系アルゴリズム) の採用
 - ▶ リード間のオーバーラップを直接ノード・エッジで表現
 - ▶ 利点: リードを k-mer に分解せず「そのまま」扱うため、HiFiリードの長さを最大限活用できる
 - ▶ 推移的なエッジを排除し、リピートを跨ぐ長い経路を明示的に保持
- ▶ アセンブルの6ステップ
 - ▶ 1. オーバーラップ検出: 総当たりマッピングによる重なり抽出
 - ▶ 2. エラー修正: ハプロタイプ情報を考慮したリードの洗練
 - ▶ 3. String Graph構築: リード間の関係を簡約グラフ化
 - ▶ 4. ハプロタイプ分離 (Phasing) : ヘテロ接合部位を利用。Hi-CやTrioデータの併用も可能
 - ▶ 5. グラフのクリーニング: バブルやチップを除去し、経路を簡素化
 - ▶ 6. コンティグ生成: グラフ上のパスをトレースし、最終的な配列を出力

Genome Assembly: de Bruijn Graph vs. String Graph


de Bruijn Graph

Uses k-mers



String Graph


Uses Reads Directly (OLC)



INPUT




k-mers




reads




GRAPH
DENSITY



REPEAT
RESOLUTION





1. オーバーラップ検出: 総当たりマッピングによる重なり抽出
2. エラー修正: ハプロタイプ情報を考慮したリードの洗練
3. String Graph構築: リード間の関係を簡約グラフ化
4. ハプロタイプ分離 (Phasing): ヘテロ接合部位を利用。Hi-CやTrioデータの併用も可能
5. グラフのクリーニング: バブルやチップを除去し、経路を簡素化
6. コンティグ生成: グラフ上のパスをトレースし、最終的な配列を出力

hifiasmの実行法

- ▶ website

<https://github.com/chhylp123/hifiasm>

- ▶ 基本的な実行法

```
$ hifiasm -o output_asm hifi_reads.fastq.gz
```

- ▶ 主な出力ファイル

- ▶ *.p_ctg.gfa: プライマリーアセンブリのコンティググラフ
- ▶ *.bp.hap1.p_ctg.gfa: haplotype 1 の部分的に分離された contig graph
- ▶ *.bp.hap2.p_ctg.gfa: haplotype 2 の部分的に分離された contig graph

- ▶ GFA形式からFASTA形式への変換

```
$ awk '/^S/{print "\>"$2;print $3}' asm.gfa > asm.fasta
```

演習

- ▶ ex303: HiFi long reads のアセンブル (hifiasm) 納豆菌
- ▶ ex302: HiFi long reads のアセンブル (hifiasm) カンジダ

Hi-C scaffolding

▶ 背景と課題

- ▶ HiFiリードによりコンティグの連続性は飛躍的に向上
- ▶ しかし、複雑な反復配列等により、コンティグのみで染色体レベル(Chromosome-level)を完成させるのは依然困難

▶ スキャフォールディング(Scaffolding)とは

- ▶ コンティグを正しい「順序(Order)」と「向き(Orientation)」で連結し、より長い配列(スキャフォールド)を構築する工程

▶ 補助情報の活用

- ▶ かつてはペアエンド、メイトペア、オプティカルマップ等を利用
- ▶ 現在は、三次元的なゲノム折りたたみ情報を活用する Hi-C が染色体スケール構築の「事実上の標準」

Hi-Cの原理とライブラリ調製

▶ 基本原理: 3Dゲノミクス

- ▶ 核内で物理的に近接しているDNA領域をクロスリンク(架橋)
- ▶ 近接した二つのゲノム座標の組み合わせをシーケンスにより取得

▶ ライブラリ調製のステップ


- ▶ 細胞・組織の固定(クロスリンク)
- ▶ ゲノムDNAの消化(制限酵素等)
- ▶ 近接断片のライゲーション(近接結紮)
- ▶ クロスリンク解除・DNA精製
- ▶ シーケンス

▶ コンタクトマトリックス(Contact Matrix)


- ▶ ゲノム座標間の「接触頻度」を表す二次元行列
- ▶ ヒートマップ可視化により、近接領域やTAD構造、染色体間相互作用が判別可能

1. Hi-C LIBRARY PREPARATION & PRINCIPLE

(1.1) PRINCIPLE: PROXIMITY LIGATION IN NUCLEUS



(1.2) WORKFLOW



Hi-C情報を利用したコンティグの統合

▶ スキャフォルディングの根拠


- ▶ 線形距離が近い領域ほど、核内でも物理的に近接し、接触頻度が高い
- ▶ 「線形距離と接触頻度の負の相関」を利用して配置を推定

▶ 解析のプロセス


- ▶ 1. クラスタリング：接触頻度の高いコンティグ群を同一染色体に割り当てる
 - ▶ 2. 順序・向きの推定：シグナルの漸減パターン(距離依存性)から隣接関係を推論
 - ▶ 3. スキャフォールド構築：推定された順序・向きに基づきコンティグを連結
- ▶ 代表的なソフトウェア：YaHS , 3d-DNA, AllHiC, SALSA2 , LACHESIS

2. CONTACT MATRIX CONSTRUCTION & VISUALIZATION

MAPPING Hi-C READS TO CONTIGS



HEATMAP (CONTACT MATRIX)



3. Hi-C SCAFFOLDING PROCESS


INPUT: INITIAL GENOME ASSEMBLY

(Random order and orientation)



Hi-C SIGNAL UTILIZATION

(i) Contig Clustering




(ii) Contig Ordering & Orientation

Use diagonal signal pattern decay to infer order and flip orientation, e.g., Conomome guide:



OUTPUT: SCAFFOLDED ASSEMBLY

(CHROMOSOME-SCALE)



POPULAR SCAFFOLDING TOOLS



Hi-C Scaffolding is the standard method for de novo chromosome-level genome assembly.

アセンブルの評価

Evaluate assembly

- ▶ Is your assembly good?
- ▶ How much is it good or bad?

Ideal assembly

- Each chromosome assembled end-to-end
- No gaps or sequence errors
- Circular genomes (e.g., bacteria) form a complete circular contig

Reality

- Many steps (library prep → sequencing → assembly): Errors can be introduced at each stage
- The “true genome” is unknown

→ **We estimate assembly quality using various metrics**

Evaluate assembly: assembly metrics

A typical example of genome assembly report in genome papers

F	Species	Assembly	Data	Sex	Size**	Assembly size	Scaffolds	NG50	BUSCO***	
					(Mbp)	(Mbp)	(#)	(Mbp)	C (%)	D (%)
	<i>Photinus pyralis</i>	Ppyr1.3	PacBio + Illumina + Hi-C	M	422 ± 9	471	2160	50.6	97.2	8.4
	<i>Aquatica lateralis</i>	Alat1.3	Illumina: short + mate-pair	F	940 ± 1.4	902	7313	0.690	97.4	1.2
	<i>Ignelater luminosus</i>	Ilumi1.2	linked-reads + nanopore	M	764 ± 7	845	91324	0.116	94.8	1.4



Firefly genomes illuminate parallel origins of bioluminescence in beetles

Timothy R Fallon^{1,2†}, Sarah E Lower^{3,4†}, Ching-Ho Chang⁵,
Manabu Bessho-Uehara^{6,7,8}, Gavin J Martin⁹, Adam J Bewick¹⁰,
Megan Behringer¹¹, Humberto J Debat¹², Isaac Wong⁵, John C Day¹³,
Anton Suvorov⁹, Christian J Silva^{5,14}, Kathrin F Stanger-Hall¹⁵, David W Hall¹⁰,
Robert J Schmitz¹⁰, David R Nelson¹⁶, Sara M Lewis¹⁷, Shuji Shigenobu¹⁸,
Seth M Bybee⁹, Amanda M Larracuenta⁵, Yuichi Oba⁶, Jing-Ke Weng^{1,2*}

(Fallon, ..., Shigenobu et al., 2018)

Assembly metrics

- ▶ Total length: アセンブリ総長。既知/推定のゲノムサイズに近いほどよい。
- ▶ #contigs / #scaffolds: コンティグ・スキヤフォルドの本数。本数が少ないほど連続性が高い(下限は染色体本数)。
- ▶ Longest contig/scaffold, Mean length: 最長コンティグ/スキヤフォルドの長さや平均長さ。長いほど連続性が高いと評価できるが、誤結合でも増大し得る点に注意。
- ▶ N50/NG50: つながり具合を示す代表的な指標(後述)。
- ▶ Ambiguous bases (N の数/割合), #Gaps / Gap length: 曖昧な塩基の数、ギャップの数や長さ。曖昧塩基やギャップは少ないほどよい。
- ▶ BUSCO スコア: 保存遺伝子セットに基づく網羅性の指標(後述)。

Assembly metrics in detail

- ▶ Contiguity
 - ▶ N50 / NG50
- ▶ Gene space coverage
 - ▶ BUSCO

N50

- ▶ Definition: Scaffold/contig length at which you have covered 50% of total assembly length
- ▶ Larger N50 means longer contiguity

Example and how to calculate

You have 5 contigs:

- 200, 800, 100, 1500, 1000 bp

Calculate total length => 3600 bp

Sort by length and calculate cumulative length

Find the contig at which cumulative / total length reach 50%

Contig size	Cumulative (bp)	Cumulative / total length
1500	1500	41.6%
1000	2500	69.4%
800	3300	91.6%
200	3500	97.2%
100	3600	100%

N50 →

50%

NG50

- ▶ Definition: Scaffold/contig length at which you have covered 50% of total **genome size**
- ▶ Larger N50 means longer contiguity

Example and how to calculate

You have 5 contigs:

- 200, 800, 100, 1500, 1000 bp

Suppose genome size is known as 5200 bp by independent analysis (e.g. flowcytometry)

Sort by length and calculate cumulative length

Find the contig at which cumulative / **genome size** reach 50%

NG50

Contig size	Cumulative (bp)	Cumulative / genome size
1500	1500	28.8%
1000	2500	48.0%
800	3300	63.4%
200	3500	67.3%
100	3600	69.2%

50%

R code

```
>len <-  
c(347628,543884,604621,122780,546334,204897,254698,76077)  
len.sorted <- rev(sort(len))  
n50 <- len.sorted[cumsum(len.sorted) >=  
sum(len.sorted)*0.5][1]  
150 <- which(cumsum(len.sorted) >= sum(len.sorted)*0.5)[1]
```

Nx/NGxを計算するR関数

```
Nx <- function(x, p = 50) {  
  x <- sort(x, decreasing = TRUE)  
  threshold <- sum(x) * p / 100  
  x[which(cumsum(x) >= threshold)[1]]  
}
```

```
Lx <- function(x, p = 50) {  
  x <- sort(x, decreasing = TRUE)  
  threshold <- sum(x) * p / 100  
  which(cumsum(x) >= threshold)[1]  
}
```


Hands-on

- ▶ Ex-304: calculate $N50/NG50$

BUSCO : アセンブリの完全性評価

▶ BUSCOとは

- ▶ Benchmarking Universal Single-Copy Orthologs の略
- ▶ ゲノムアセンブリの完全性(Completeness) を定量化する標準の指標
- ▶ BUSCO, <http://busco.ezlab.org>.

▶ 基本的な考え方

- ▶ 「特定の生物群(系統)において、普遍的に1コピーで存在するはずの遺伝子群」がどれだけ含まれているかを調べる
例: 昆虫(Insecta) のセット(1,367遺伝子)のうち、いくつ検出できるか?

▶ OrthoDBに基づく分類群別セット

- ▶ 対象生物に合わせて適切なセットを選択することが不可欠
- ▶ 例: Bacteria, Eukaryota, Insecta, Mammalia など

BUSCOの使い方

- ▶ website

<http://busco.ezlab.org>

- ▶ 基本的な実行法

```
$ busco -m genome assembly.fasta -o OUTPUT -l insecta
```

- ▶ 主要なアウトプット

```
C:97.2%[S:93.1%,D:4.1%],F:0.8%,M:2.0%,n:1066
```

```
1036    Complete BUSCOs (C)
992 Complete and single-copy BUSCOs (S)
44  Complete and duplicated BUSCOs (D)
9   Fragmented BUSCOs (F)
21  Missing BUSCOs (M)
1066   Total BUSCO groups searched
```

BUSCO output example

```
C:97.2%[S:93.1%,D:4.1%],F:0.8%,M:2.0%,n:1066
```

```
1036    Complete BUSCOs (C)
992 Complete and single-copy BUSCOs (S)
44  Complete and duplicated BUSCOs (D)
9   Fragmented BUSCOs (F)
21  Missing BUSCOs (M)
1066   Total BUSCO groups searched
```

- ▶ スコアの意味
 - ▶ Complete (C) : 完全長で検出された遺伝子
 - ▶ Single-copy (S) : 期待通り1コピーのみ存在(理想的)
 - ▶ Duplicated (D) : 複数コピー検出
 - ▶ Fragmented (F) : 断片的にのみ検出
 - ▶ Missing (M) : 検出されなかった(未解読領域、または遺伝子の欠失)
- ▶ 理想的なアセンブリの条件
 - ▶ C が100%に近く、D・F・M が極めて低いこと
- ▶ 重複(D)が多い場合の解釈
 - ▶ ヘテロ接合性が高く、本来統合されるべきハプロタイプが別々のコンティグとして残っている可能性

BUSCOの幅広い用途と解析コマンド

▶ 多目的な評価対象

- ▶ ゲノム (genome) : アセンブリの網羅性を評価
- ▶ トランスクリプトーム (transcriptome) : RNA-seqの組立て結果を評価
- ▶ タンパク質 (proteins) : 予測された遺伝子セットの網羅性を評価

▶ 利用可能な分類群セットの確認:

- ▶ `--list-datasets` オプション

Hands-on

- ▶ ex305: BUSCO ex302 (hifiasmによるカンジダゲノム)のアセンブル評価

その他の評価方法・指標

- ▶ k-mer 完全性と QV (Merqury)
 - ▶ 入力リードとアセンブリの k -mer 集合を比較し、再現性を評価参照ゲノム不要で、エラー率推定や QV (Quality Value) の算出が可能
- ▶ 構造的誤結合の検出 (QUAST)
 - ▶ 参照ゲノムとの比較により、配列の過剰結合 (Chimeric) や断片化を特定
 - ▶ 統計情報 (N50等) に加え、アセンブリの整合性を多角的にレポート
- ▶ マッピングベース評価 (Read Back Mapping)
 - ▶ リードをアセンブリに再マッピングし、カバレッジの一様性を確認
 - ▶ IGV 等での目視確認により、リピートの誤処理や欠落を特定
- ▶ 生物学的妥当性の検証
 - ▶ 保存性の高い遺伝子群 (Hox 遺伝子群など) のシンテニー (並び) を確認
 - ▶ 性染色体やオルガネラゲノムの完全性をチェック
- ▶ Blobtools: 混入配列の検出
 - ▶ 各コンティグを GC 含量・カバレッジ・系統情報 (Taxonomy) でプロット
 - ▶ 外来の細菌・真菌や共生生物の配列を視覚的に分離・識別 (Blobplot)