基礎生物学研究所
ゲノムインフォマティクス・トレーニングコース2026年3月

ゲノムのアノテーション

Genome Annotation

Shuji Shigenobu
NIBB, Japan
<shige@nibb.ac.jp>

実験室

DNA抽出

▽

DNA断片化・
ライブラリー作成

▽

シーケンシング

▽

コンピュータ

アセンブル

▽

スキャフォルディング

▽

遺伝子予測・注釈づけ

▽

生物学的解釈

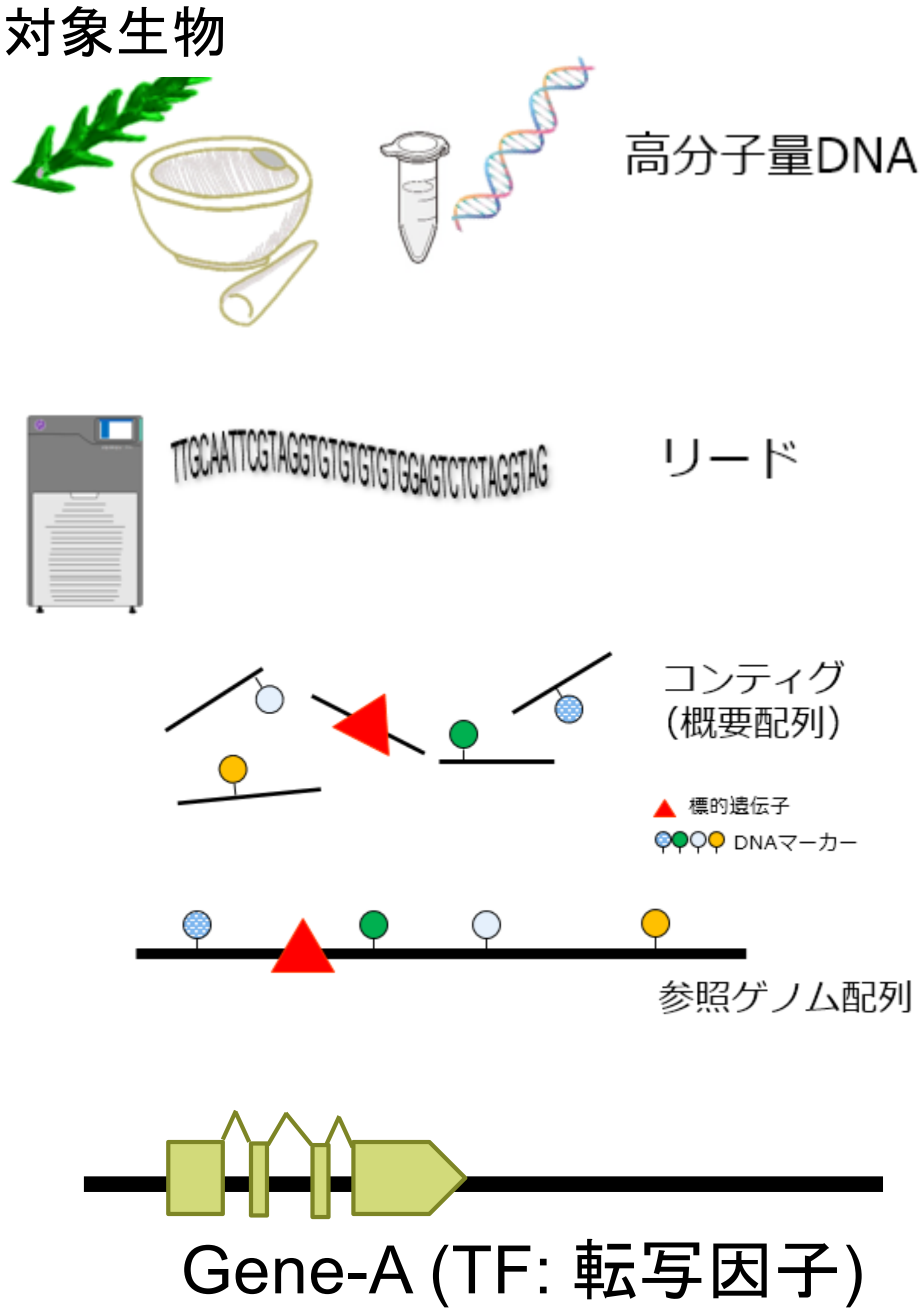

```
20221 gaggcacgag aatcacttga acccaggagg tggaggttac agtgagccga gatcgtgcca
20281 ttgcactcca gtctgggtga cagactgagg ctccatctca acaaaaaaaa aaggaaagaa
20341 agaaattcac tgagcccaac ttaaacgata gagtcaagag gtctctaatg caaaaggcca
20401 ttgagtctca ctcacctccc tgcttgcttc attctcctca gctacactgg ctttgagggc
20461 cagtttttac attgggacct ggtagcccac accacctgtt cttgtacctc catgcctgat
20521 tccagccagg ctaagctgtc atcttttagt tgtaatgcca tattcctgag ggaggaccct
20581 gagtggctgg ccttggttct ggccagctgt ggccaagggt ggacagatca tttgtgtaca
20641 taatggctgc ctccctatga catgtaaaca gaggtggtgg ggaggaagca gtgccagaag
20701 agtagaggtt ggacaagaaa acagttgggc cgggcgcagt ggctcactcc cataatccca
20761 gcagtttggg aggccgagct gggtggatca cctgaggtca ggagttcgag accagcctgg
20821 ccaacatgat gaaaccccgt ctctactaaa aatacaaaac ttaggctgtg cgcggtggct
20881 catgcctgta atcccagcac tttgggaggt cgcggcgggg ggatcacgag gtcaggaaat
20941 cgagaccatc ctggctaaca cggtgaaacc ccatctctac taaaaatata tatatataaa
21001 aaattagctg ggcttggtgg caggcgccta tagtcccagc tactcaggag gctgaggcag
21061 gagaatggtg tgaacctggg aggtggagct tgcagtgagc tgagatcgcg ccactgcact
21121 ccagcctggg caacagagcg agactctgtc tcagaaaaaa aaataaaaaa taaaaaaatt
21181 aaaacttaga tgggcgtctt ggcaggcatg ctacttggga gtctgaggca ggagaaccgc
21241 ttgaacctgg gaggcggagg ttgcagtgag ctgagatcgc gccactgcac tccagcctgg
21301 gagacaagag cgagacttcg tctcaaaaaa aagaaaaaaa aaaagaaaac agtcggtatc
21361 cttcacaaca ggtgcacaca gccagggcaa tcacgcctcc ccggggacac tgggcaatgt
21421 ccagagacat ttttggcagc ctcgactgcg aggggaaggg tactactggc atctagtgga
21481 tagaggtcag agatgctgct caacatcgta caatgcccag gacagtccca caacaaagaa
21541 ttctccagcc ccagatgtca gcagtgccaa ggctgaaaaa ctccctctgc aaggacaccc
21601 cagagagagc agcctggtac atctcagttg gggccacatg ctttcctgaa ttttggcatt
21661 ctgcttttgt gctgatgaaa taacttctgg ggcttgcaaa acacatgtca tgtagactgt
21721 gtttgtatag atctgggga gggaagctgc aatgcctggg cttgcataga ttggcaaccc
21781 cctagctagc tttcttccag ggtcacaaac ccatgttcaa acccaggtca ctagccaggt
21841 gctaatggct cgagcctgta atcccagcac tttgggaggc caaggcagga ggatcacttg
21901 agctcaggag tttgagagca gcctgggcaa tatagggaga cccacatctc tacaaaaaat
21961 ttaaaaacat tagccaggca tggtgacatg tgcctgtagt ctcagctact caggaggcta
22021 aggtgggagg atcacttgag cccaggaggt caaggctaca gtgagttatg attgtgccac
22081 tgtactccag cctgggcaac tgagcaagac cctgtttctt tctttctttt cttttttttt
22141 tttttttttg agacagagtc tcgctctgtt gcccaggctg gagtacagtg gcgtgatctc
22201 ggctcactgc aacctccgcc tcccaggttt aagccattct tctgcctcag cctcccgagg
22261 tgctgggatt acaggcaccc gccaccacgc ccagctaatt ttttgtattt ttagtagaga
22321 cggggtttca ccaccttggc caggctggtc tcgaactcct gacctcgtga tctgctcacc
22381 taggcctccc aaagtgctgg gattacaagt gtgagccacc acacccagca agaccctgtt
22441 tcttaaaaaa aacaaagaag gtcaggcatg gtggcaggtg cctgtaatcc cagctacttg
22501 ggaggctgag gtagagaatc gcttgaacct gggggccga ggttgcagtg agcccagatc
22561 acaccactgc actccatcct gggagacaga gcgagacgct gtctcaaaaa aaaaaaaaga
22621 aaagaaaaga aagaaaaaaa aaaaatctaa ttcctgggca tgagccccag agagtgggat
22681 tgagtagatt ggaaatggac tcctgggatc tggtgttttt tacaagaacc ccaggcgatt
22741 ctgaggcttg ggggttagct acctagagta gattttcgtg acctttgcag tcacttgtct
22801 ctctctgaat aagccaaaag caaagacagt tttcagaaag actcagctgg accagtttga
22861 gtcttctctt tctgccaggg tttgcagggg tccctgacaa tcattgattc gagcttgaac
22921 gtttctttgt ttaaaggtat tatgccggct gggctgataa gtaccacggg aaaaccatcc
22981 ccattgacgg agacttcttc agctacacac gccatgaacc tgtgggggtg tgcgggcaga
23041 tcattccggt gagtccagcc tccctggagt ttcttcaggg tgccctgaga tttggcagtc
23101 tgccagactc attgcagagg ttctggggtg gtgtcggaag gcagcctggg tggcaggtaa
23161 gaagatgggc tctgacaaag ccaatccggt ttgagtctca gcactgccac tcgtgaattc
23221 tgtaaccttg ggcaagtcac ttatccccca agcctcagtt tccccatctg aaaagtggaa
23281 atgaacatag tgcctgtctt agggaggtaa ttagggctta gcatggtgtc acggacataa
23341 aagcacggat aaatgtgagt ctgtcatcgt tgtgcaccgc ctgcctcatc cattcatctt
23401 aaaaccacga tggatggagt taggggagga cacgcagggt tcagagaact cggtgctgct
23461 tctgccctct ggggttgcca ccttctgcta cccagtgtag ttctctgagg aagcttggat
23521 ttcgagggct gctgttgttt gttgcagtgg aatttcccgc tcctgatgca agcatggaag
23581 ctgggcccag ccttggcaac tggaaacgtg gttgtgatga aggtagctga gcagacaccc
23641 ctcaccgccc tctatgtggc caacctgatc aaggaggtgc gtggcttatc ctggtcttaa
23701 cctctaaatg cccttgttga ggcttgttct aaaggagttc tgagaagggt ctcaggggtc
23761 cctaaacagg gaggtgtgtt tgtggagccc ccatcaccat gtgaaccaga gtggctccct
23821 cttagctttt ttccacattg gacttcactg caagatcccc tttgaagaat taaaaatatt
23881 gctctaggcc aggcttggtg gctcacgcct gcaatcccag cactttgggt ggccaaagca
23941 ggagggttgc ttgagttcag gagtttgaga ccagcctgag caacatagca agaccccatc
24001 tctacaaaaa attaaaaatc agctgggtgg catgcacctg tagtcccaac tacttgggag
24061 gttaaggcag gaggatcact tgagcccagg agtttgaggc tgcagtgagc tgtgatcaca
24121 ccactgcact ccagcctggg tgccagagag agactcggtc tcaaaaaaca aacaaaaacc
24181 cactgttgtt ctaagtgaat gctgtcaggg gaggggcaaa gacacaggga accccagcga
```

human chromosome 12 (partial)

注釈付け

Genome **annotation**

Definition:

1. **Structural annotation**: the process of identifying genes and their intron-exon structures.
2. **Functional annotation**: the process of attaching meta-data such as gene ontology terms to structural annotations.

```
20221 agattgtctg caaggcctgt gcttttcatt tgtaggctac accactctga aattaattca
20281 tatttgcttt ttcttgtttt ttttttcct tacaatactg gtagtcagta ttaggttgac
20341 agctggtcct gagaacttct ttccttctca ttgtagattt tcataaacaa tgaatggcac
20401 gatgccgtca gcaggaaaac attccccacc gtcaatccgt ccactggaga ggtcatctgt
20461 caggtagctg aaggggacaa ggtgagaact ggtgacttac cttgggggag ggatggattc
20521 gtcttctatt ttatacgttt ttgtgtggtg aaagctttac catatatgtg tattactttc
20581 acaagtaaca gataccagtg aaaaattccg agtaaattaa tcaatagaaa cttgtctgca
20641 gacaacggtg ttaattcact tagtgtagaa ctatagactt agaagtgaat tcggcaaata
20701 tctaatacag tgtctccttt ccagacctgg aagttgaagg tcagagatgg aaaccttgct
20761 gggtagaatt tgggtctcct aagatctagc tcctgtggag gtttgaattg tacagactgt
20821 aggaaccaat cgaaactgat aatattctgt ttaaaatttt taaattagac tcttagtaaa
20881 aatattttgt gtttttggcc gggcgcagtg gcgcaggcct gtaatcccag cactttggga
20941 ggctgaggtg ggaggatcac ttgaacccag gaatttgaga ccagcccggg gaaacatagt
21001 gagataccat ctctaaagta aacaaagaaa caaataagta atttaaaact aagaaaatac
21061 aggccaggcg cagtggctca agcctgtaat cccagcactt tgggaggcca aggtgggcag
21121 atcatgaggt caggagtttg agaccagcct gaccaacatg gtgaaacccc gtctctacta
21181 aaaatacaga aattagccag gtgtggtggc atctcttgag taatcccagc tactcaagag
21241 gctgaggtag gataattgct tgaacccggg aggcggaggt tgcaatgagc cgagattgcg
21301 ccactatact ccagcctggg cgacagagcg agatttcgtc tcaaaaaaaa aacaaaaaaa
21361 aagaaaatac agaaattatc cggattctca ttcccaccag gacttcatga aaggagggga
21421 aggtcatgtt attcaacccc attgctgaag tctggtgctc atcagggctc tgccgggcta
21481 ggagcattgt ttacggggca ggtttctgt gcagcgatat gctgatgacc ttctggatgt
21541 gtttgtattc ggacctggtt attactgaga agacctgagt tttccaggaa ggcttgagtt
21601 ttcctgtgtt ttctaggaag atgtggacaa ggcagtgaag gccgcccggg ccgccttcca
21661 gctgggctca ccttggcgcc gcatggacgc atcacacagg ggccggctgc tgaaccgcct
21721 ggccgatctg atcgagcggg accggaccta cctggcggtg agtcctcagc ccttctcccc
21781 ctcagatccc atgtggtgaa taggctcgca gcatcctgtg aacagccagg aaccaagcat
21841 cctgtgaaca gccagggaac acacatctga cacgggactg atgggaatgg cataggatgg
21901 acacctttag gggcacctc tgtactaacc agaggagcct ttcagtgtct cctttgtttt
21961 tttgttttgt tttgttttgc tttttgaga tggagtctca ctctgtcgcc taggctggag
22021 tgcagtggcg acatctcggc tcactgcaac ctccacctcc tgggttcaag tgattctcct
22081 gcctcagcct cccaagtagc tggaattaca ggcacaagcc accacgcaca gctaatttgt
22141 gtatttttag tagagacaag gtttcaccat gttggccagg ctggtctcca acccttgggc
22201 tcaagtaatc cacctgcctc agcctcccaa agtgctggga ttacaggcgt gagccaccgc
22261 acctggcctt tgatgcggcg ggtttggcta agcaagaagg atctgggga ggggagagga
22321 gctgtgtcag ggaggccttc ccaggagaga gacccctggg aatggacacc tctccctcgg
22381 cccctccatg gtgggccttc tccctggctg caagaggaga agaaaccagg aggcaatctc
22441 ctcccagcca caattgattc tgcacacaga agccagagca aaccttccag aaggcagatt
22501 atacatggca ctctgctctt atccctgcat ggcatgcggt gtccttagga taaaatcctc
22561 aacatggtct gtaagaccag cctgtaacat ggcaagatcc tgtctctaca aaaagttaaa
22621 aaactagctg agtatggtgg catatgcctg tagtcctagc tacatggtag gctgaggcag
22681 gaggcttgct tgagcccagg agttcaaggc tgcagtgagc tgttgtggtg ccactgcgct
22741 ccagcctggg caacagagtc agatcctgtc tcaaaaaaaa aatgacccag cctgttctag
22801 ttccatcatc tgagtcatgc tgcactgcag tcctcacatt cacatgtgct cctgagcctg
22861 ggctcccatg cttgatggcc aagcctcttt gagcatcagc gcttgcacct gcctgggatg
22921 ctcttcgccc tgctgccatc tgtaccatcc cctttgccca gttgccccct acatatcatt
22981 caggttctag cctaaagggc tcatctctgg ctgatgtttc tagacagggc tgggcagcct
23041 ggctccctgc tttctatttt ttagcattct tttattatta ttattatttt ttgagatgga
23101 gtctcactct tcacccaggc tggagtgcaa tggcacaatc tcggctcact gcaacctcta
23161 cctcccaagt tcaagcaatt ctcctgcctc agcctcccca ctagctggga ttacaggtgt
23221 gcaccaccat gcccagctaa ttttgtattt ttgataaagt caaggtttca ctgttttggt
23281 caggctggtc tcgaacacct gcctcggcct cccaaagtgc tgggattata gctgcaagtc
23341 actacatccg gcctctagca ctcttaacac atgtgactga ggacttgtgt cattatgcac
23401 agtctctttg ctctgtaagc tccacgctgg tctctatccc agcacctgga tatggtagag
23461 agcagaagct aaaagagtgt gtttatgaaa tcactgagtg agaaattggt ggctcatcct
23521 gcctggcccc cttcctcctc ctccctgcct ttggagagac catggcaata gtccagagat
23581 gctagtgaca tttggggcac aaagcggact ctcaccctgg gcttgcacca gcccttctca
23641 gtcccagcct tggcgccctc tgtcagccct ttgttttcct ctcattcctg cacccatgtc
23701 tctgctgacc ttgttttctt ctcaggcctt ggagaccctg gacaatggca agccctatgt
23761 catctcctac ctggtggatt tggacatggt cctcaaatgt ctccggtatg ggctcagctt
23821 tcctgttctt tgttctggca ggggaaaagg ggaggcaacg ttgttaggag gtaaaaatta
23881 aattacaaaa attcaaaagg ggcagagcgc ggtatctcat gcctataatc ccagcacttt
23941 gggaggctga gccaggtgga ttacgtgagg tcaagagttt gagaccagcc tggtcaacat
24001 gatgaaaccc catctctact aaaaatacaa aaattagctg ggcatggtgg cgcacacctg
24061 taataccagc tactcaggag gctaaggtag aagaatctct tgatccctgg aagtggaggt
```

exons

>gi|238776813:5346-48444 Homo sapiens aldehyde dehydrogenase 2 family (mitochondrial) (ALDH2), RefSeqGene on chromosome 12

Homo sapiens aldehyde dehydrogenase 2 family (mitochondrial) (ALDH2), RefSeqGene on chromosome 12

NCBI Reference Sequence: NG_012250.1

GenBank FASTA

Link To This Page | Feedback

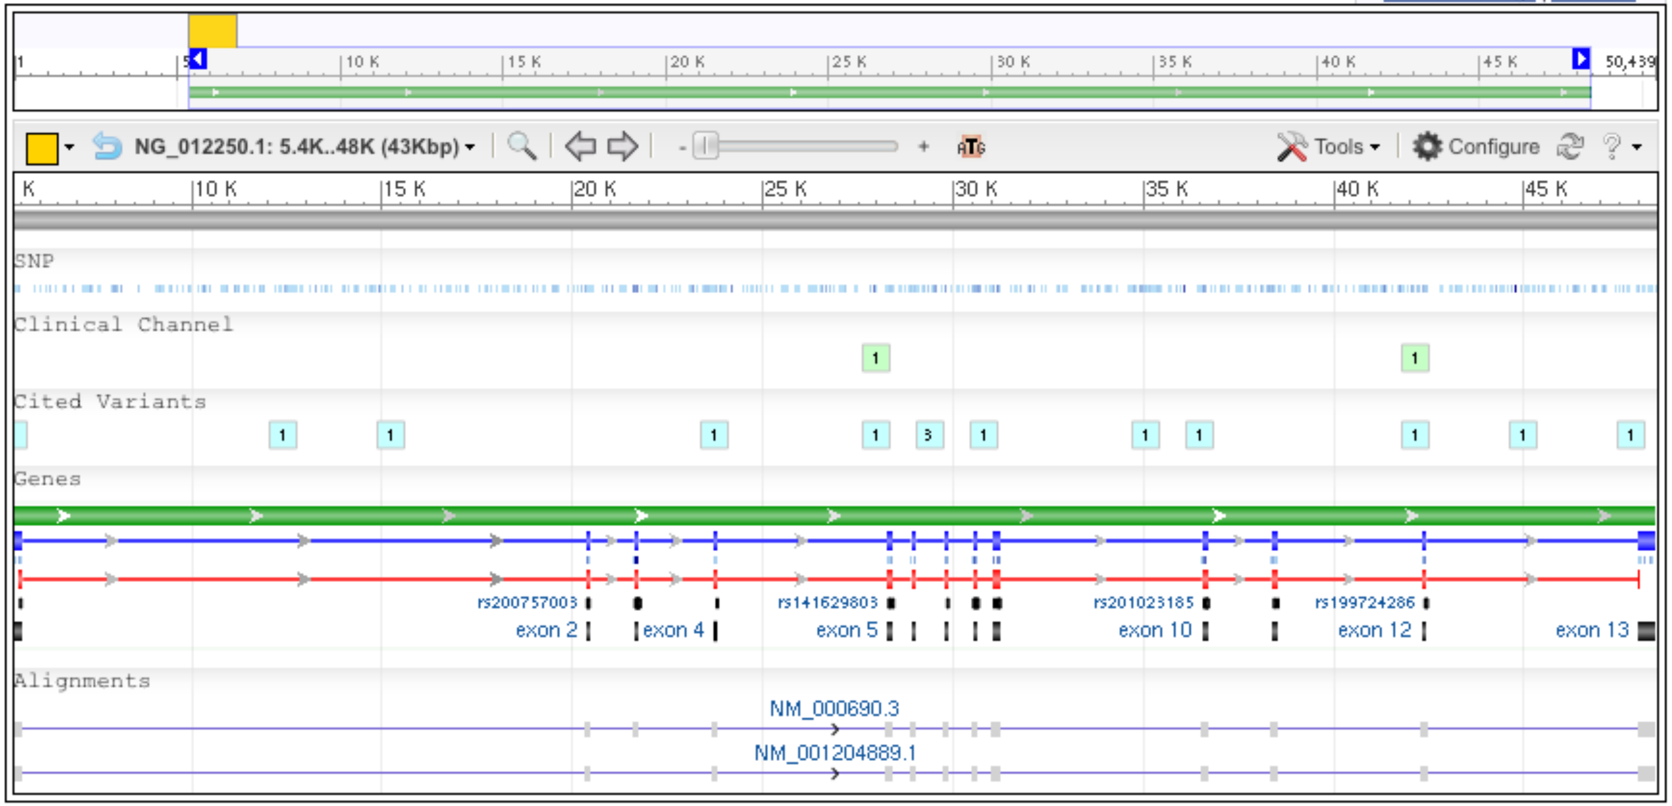

Functional annotation

Summary

Official Symbol	ALDH2 provided by HGNC
Official Full Name	aldehyde dehydrogenase 2 family (mitochondrial) provided by HGNC
Primary source	HGNC:404
See related	Ensembl:ENSG00000111275; HPRD:00003; MIM:100650; Vega:OTTHUMG00000169603
Gene type	protein coding
RefSeq status	REVIEWED
Organism	Homo sapiens
Lineage	Eukaryota; Metazoa; Chordata; Craniata; Vertebrata; Euteleostomi; Mammalia; Eutheria; Euarchontoglires; Primates; Haplorrhini; Catarrhini; Hominidae; Homo
Also known as	ALDM; ALDHI; ALDH-E2
Summary	This protein belongs to the aldehyde dehydrogenase family of proteins. Aldehyde dehydrogenase is the second enzyme of the major oxidative pathway of alcohol metabolism. Two major liver isoforms of aldehyde dehydrogenase, cytosolic and mitochondrial, can be distinguished by their electrophoretic mobilities, kinetic properties, and subcellular localizations. Most Caucasians have two major isozymes, while approximately 50% of Orientals have the cytosolic isozyme but not the mitochondrial isozyme. A remarkably higher frequency of acute alcohol intoxication among Orientals than among Caucasians could be related to the absence of a catalytically active form of the mitochondrial isozyme. The increased exposure to acetaldehyde in individuals with the catalytically inactive form may also confer greater susceptibility to many types of cancer. This gene encodes a mitochondrial isoform, which has a

http://www.ncbi.nlm.nih.gov/gene/217

Genome **annotation**

Definition:

1. **Structural annotation**: the process of identifying genes and their intron-exon structures.
2. **Functional annotation**: the process of attaching meta-data such as gene ontology terms to structural annotations.

- ゲノムアノテーションは、配列情報に意味を与える重要なプロセスであり、ゲノム情報を機能的に活用するための基盤となる。他の生物のゲノムと比較する上でも重要なプロセスである。

Structural annotation

- Gene prediction (protein coding gene) << Main task
- Repetitive sequence
- Misc
  - UTR
  - Pseudogene
  - Non-coding RNA
  - Regulatory elements

Gene prediction

- Evidence-driven gene prediction
- *Ab initio* gene prediction

Gene prediction

- Evidence-driven gene prediction
  - Definition: A gene finding system that the target genome is searched for sequences that are similar to extrinsic evidence in the form of the known sequence of a mRNA or protein product.
  - 1) Transcript mapping based on EST, RNA-seq data
    - The most straightforward way for annotating exon-intron structures. Transcript sequence data obtained with EST or RNA-seq project are aligned to a genome.
  - 2) Homology search

Gene prediction

- Evidence-driven gene prediction
  - Definition: A gene finding system that the target genome is searched for sequences that are similar to extrinsic evidence in the form of the known sequence of a mRNA or protein product.
  - 1) Transcript mapping based on EST, RNA-seq data
  - 2) Homology search
    - Align cDNAs (or proteins) from homologous genes of other species. A useful approach to annotating genes for which there is little or no cDNA.

Gene prediction

- *Ab initio* gene prediction
  - Definition: An approach to gene prediction in which the only inputs are genome sequences.
  - Find ORFs
    - Search start ATG codon and stop codons.
    - Easy for prokaryotes.
    - Inefficient for eukaryotes due to intron-exon structure.
    - Intron-exon structure can be taken into consideration.

Gene prediction

- Combined approaches
  - *ab initio* prediction + evidence-based prediction
  - Modern gene predictors implement this approach.

  - A general workflow
    - 1) Collect reliable evidence
      - Accurate cDNA sequences, well-annotated homologous sequences
    - 2) Training by the evidences
    - 3) Gene prediction based on trained data

  - Merge multiple predictions:
    - Different prediction software produce different gene sets and different structures. "Choosers and combiners" software choose and merge gene models.

Gene prediction in practice

- Bacteria
  - Algorithm and software are well developed. Accurate prediction expected.
  - ab initio approach works very well
  - Software examples:,Glimmer, GeneMark, Prodigal

- Eukaryote
  - Still difficult.
  - Hybrid approach (ab initio + evidence) is common
  - Software examples: Augustus, BRAKER

遺伝子予測のアルゴリズムとソフトウェア

- 原核生物の遺伝子予測（成熟した分野）
  - 特徴：イントロンがなく構造が単純。ゲノム配列のみで高精度な予測が可能
  - 手法：ab initio 法（塩基組成やコドン使用頻度に基づく予測）が主流
  - アルゴリズム：隠れマルコフモデル（HMM）を活用
  - 代表的ツール：Prodigal、GLIMMER3
  - 活用例：Prokka や Bakta といった総合パイプラインに組み込まれている

遺伝子予測のアルゴリズムとソフトウェア

- 真核生物の遺伝子予測（複雑かつ発展途上）
  - 特徴： エクソン・イントロン構造、可変スプライシングにより構造が極めて複雑
  - 手法： HMM単独では限界があり、実験データ（RNA-seq）やホモログ情報の統合が不可欠
  - 代表的ツール：
    - 古典的 HMM： AUGUSTUS, GeneMark-ET, FGENESH
    - 統合パイプライン： BRAKER, MAKER（証拠データを自動統合しトレーニングを実行）
    - 最新動向： Helixer など、深層学習ベースの手法が登場

Prodigalによる原核生物の遺伝子予測

原核生物遺伝子予測のスタンダード

- Website: https://github.com/hyattpd/Prodigal
- タイプ: ab initio 型（ゲノム配列のみから予測）の遺伝子予測ツール
- 特徴: 事前トレーニング不要。極めて高速かつ高精度な予測性能
- アルゴリズムの主要な特徴
  - 統計的アプローチ: コーディング領域と非コーディング領域の塩基組成統計を比較
  - 隠れマルコフモデル（HMM）　:　最適な遺伝子モデルを動的計画法で探索
  - 精緻な開始点推定: シャイン＝ダルガーノ（SD）配列や開始コドン周辺の特徴を考慮
  - 柔軟性: 染色体だけでなく、プラスミドなどの短い配列にも対応
- メタゲノムモード（-p meta）
  - 対象: メタゲノム由来の断片化されたコンティグ集合
  - メリット: 種やGC含量が混在する環境でも、安定した予測結果を出力可能
  - 遺伝子が途中で切れている断片的な配列に対してもロバスト（頑健）な設計

Prodigal の使い方

- Input
  - Genome seuquence (FASTA)

```
prodigal -i genome.fna -o genes.gbk  -a proteins.faa -d
genes.fna
```

- Output (主なもの)
  - out.gff << → 遺伝子位置情報（主要な結果）
  - protein.fasta → 予測されたタンパク質配列
  - transcript.fasta → 予測された遺伝子塩基配列

演習

- ex402 -- バクテリアの遺伝子予測　(prodigal) ブフネラ

BRAKER3による真核生物の遺伝子予測

真核生物ゲノムのための自動遺伝子予測パイプライン

- Website: https://github.com/Gaius-Augustus/BRAKER
- ハイブリッド手法: 外来エビデンス（RNA-seq, タンパク質ホモログ）とab initio 予測を統合
- 主要コンポーネント: GeneMark、AUGUSTUS、TSEBRA（統合ツール）
- 必要な入力データ（標準モード）
  - ゲノム配列
  - RNA-seqデータ: マッピング済みBAMファイル
  - タンパク質配列: 近縁種の高品質なアノテーションデータ

BRAKER3 による真核生物の遺伝子予測

- 解析の4ステップ（内部ワークフロー）
  - ヒント（Hints） の生成： RNA-seqからエクソン境界を、タンパク質からCDS構造を抽出し、予測の補助情報を作成
  - GeneMark による初期予測：ヒントを活用してゲノム全体の粗い遺伝子モデルを学習・予測
  - AUGUSTUS による高精度予測： GeneMarkの結果をトレーニングデータとして使い、ヒント情報を統合して精密な構造を予測
  - 統合・選別（TSEBRA） ： 複数の予測結果を比較・統合し、最も信頼性の高い最終遺伝子セット（GTF形式）を出力
- 柔軟性なパイプライン
  - RNA-seqデータが利用できない場合や、ホモログ情報が利用できない場合でも、柔軟にパイプラインを変更して遺伝子予測を行うことが可能である。た

BRAKER3 の使い方

- Input
  - ゲノム配列：リピート配列をソフトマスク済みのもの
  - RNA-seqデータ：スプライス対応アライナー（HiSat2/STAR等）によるマッピング済みBAMファイル
  - タンパク質配列：近縁種の高品質なモデル（OrthoDB等）

```
$ braker.pl \
  --genome=assembly.repeatmasked.fasta  \
  --bam=RNAseq.bam \
  --prot_seq=OrthoDB_Arthropoda.fasta \
  --workingdir=outdir \
  --threads 16
```

- Output (主なもの)
  - braker.gtf ：最終的な遺伝子予測結果（GTF）
  - braker.codingseq：予測CDS配列（FASTA）
  - braker.aa：予測タンパク質配列（FASTA）
  - （AugustusやGeneMarkの中間予測結果も出力される）

演習

- ex403 -- 真核生物の遺伝子予測 (BRAKER3) カンジダ

Repetitive Annotation

- Many genomes contain a large fraction of repetitive sequences - e.g., ~50% of the human genome is derived from repeats
- Once regarded as "junk DNA," repeats are now known to hold functional and/or evolutionary relevance
- => Accurate identification and annotation of repeats is a key step in genome analysis
- Repeats can interfere with downstream analyses (e.g., gene prediction, structural annotation)
- => Repeat regions are often masked prior to downstream steps

Types of repeats

- 1. Transposon-derived repetitive elements
- 2. Simple sequence repeats
- 3. Segmental duplications.
- 4. Non-interspersed repeats

Repetitive elements: Transposons

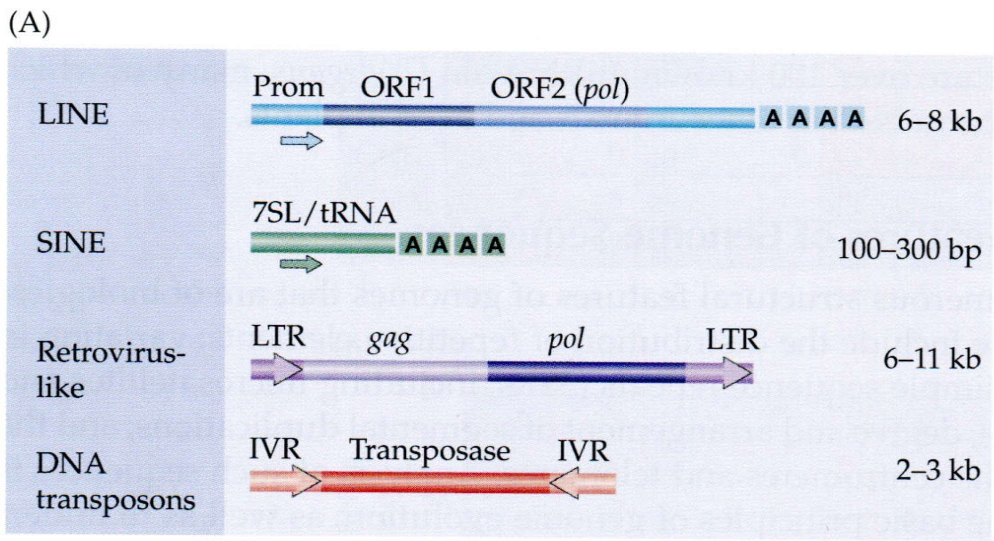

- LINEs (Long Interspersed Elements) and SINEs (Short Interspersed Elements) are 2 classes of Non LTR Transposons.
- Non-LTR Retrotransposons transpose through an RNA intermediate utilizing a reverse transcriptase and lack flanking terminal repeat sequence (LTRs).
- LINEs are ~ 6 Kb long, Observed in protozoans, insects, and plants. Abundant in mammalian genomes
- SINEs are ~ 300 bp long and are found primarily in mammalian DNA

Repetitive elements: Transposons

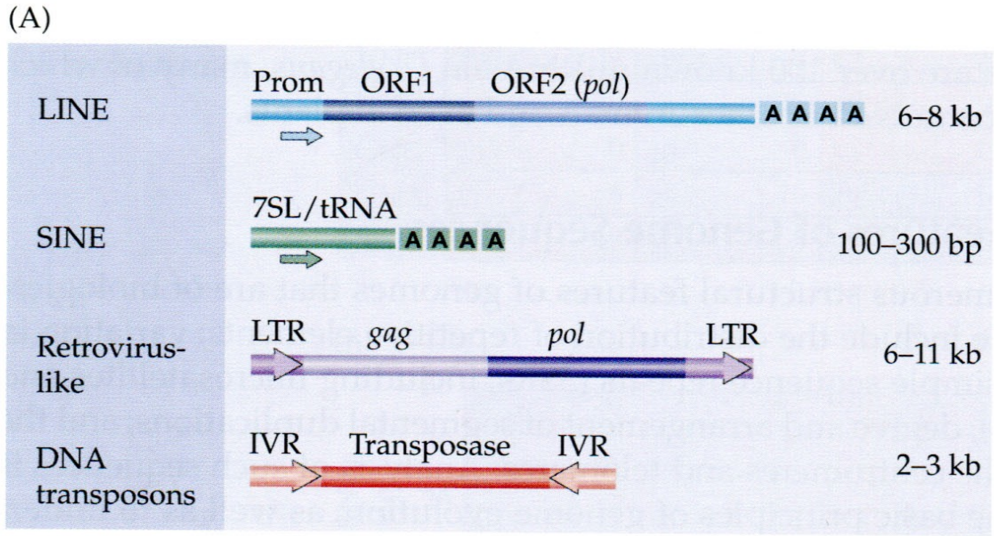

- LTR retrotransposons are generally 5–7 kb long. They are characterized by having long terminal direct repeats (LTR) a few hundred base pairs long between which there are open reading frames equivalent to the ***gag*** and ***pol*** genes of a retrovirus.
- DNA transposons generally move by a cut-and-paste mechanism in which the transposon is excised from one location and reintegrated elsewhere. DNA transposons consist of a transposase gene that is flanked by two Inverted Repeats (IVRs)

Types of repeats

- 1. Transposon-derived repetitive elements
- 2. Simple sequence repeats
  - Microsatellite
  - Short tandem repeats, STR
  - Telomere (human: TTAGGG)
- 3. Segmental duplications.
- 4. Non-interspersed repeats
  - Ribosomal DNA etc.

Annotation of repetitive elements

- Example software: RepeatModeler & RepeatMasker

RepeadMasker Output

```
==================================================
file name: CerJap_SN190829.idcln.fasta
sequences:         22369
total length:  601482826 bp  (555654606 bp excl N/X-r
GC level:         33.49 %
bases masked:  238797495 bp ( 39.70 %)
==================================================
               number of      length   percentage
               elements*    occupied  of sequence
--------------------------------------------------
Retroelements        81440     59287878 bp    9.86 %
   SINEs:                0            0 bp    0.00 %
   Penelope           4407      1413610 bp    0.24 %
   LINEs:            66450     46451234 bp    7.72 %
    CRE/SLACS            0            0 bp    0.00 %
     L2/CR1/Rex       6194      3095704 bp    0.51 %
     R1/LOA/Jockey   18437     17152077 bp    2.85 %
     R2/R4/NeSL         37         9586 bp    0.00 %
     RTE/Bov-B       22537     10656143 bp    1.77 %
     L1/CIN4             0            0 bp    0.00 %
   LTR elements:     14990     12836644 bp    2.13 %
     BEL/Pao          5048      3239708 bp    0.54 %
     Ty1/Copia         447       147439 bp    0.02 %
     Gypsy/DIRS1      9063      9057097 bp    1.51 %
       Retroviral      144        15954 bp    0.00 %

DNA transposons     158062     61741470 bp   10.26 %
   hobo-Activator    98286     36248652 bp    6.03 %
   Tc1-IS630-Pogo    27995     10990272 bp    1.83 %
   En-Spm                0            0 bp    0.00 %
   MuDR-IS905            0            0 bp    0.00 %
   PiggyBac           3001      1426271 bp    0.24 %
   Tourist/Harbinger  5521      2079227 bp    0.35 %
   Other (Mirage,     2250       768152 bp    0.13 %
    P-element, Transib)

Rolling-circles      10365      5769869 bp    0.96 %

Unclassified:       425517     95196067 bp   15.83 %

Total interspersed repeats:   216225415 bp   35.95 %


Small RNA:               0            0 bp    0.00 %

Satellites:              0            0 bp    0.00 %
Simple repeats:     328855     14976058 bp    2.49 %
Low complexity:      37723      1826153 bp    0.30 %
==================================================
```

RepeatModeler & RepeatMasker

- リピート解析の標準ワークフロー
- Website: https://github.com/Dfam-consortium/RepeatModeler
  https://www.repeatmasker.org/
- RepeatModeler : de novo リピート検出
  - 役割 : 既知のデータベースに頼らず、そのゲノムに特有のリピートを「新しく見つける」
  - 仕組み : RepeatScout (k-mer解析) や RECON (クラスタリング) 等を統合
  - 入力 : ゲノム配列
  - 出力 : 種特異的な「リピートコンセンサス配列ライブラリ」(-families.fa)
- RepeatMasker : 既知リピートの探索とマスキング
  - 役割 : ライブラリや既存DB （Dfam等）と照合し、ゲノム上のリピート位置を特定
  - 入力 : ゲノム配列、リピートライブラリ（Public/Custom）
  - マスキングの種類 :
    - ソフトマスク（Soft Masking） ： 該当領域を「小文字」にする（遺伝子予測で推奨）
    - ハードマスク（Hard Masking） ： 該当領域を「N」 で置換する

RepeatModeler

- Input: genome (FASTA)
  - データベース作成

```
$ BuildDatabase -name NAME genome.fasta
```

  - リピート検索実行

```
$ RepeatModeler -database NAME threads 12 -LTRStruct
```

- Output
  - [NAME]-families.fa → 検出されたリピートファミリーごとのコンセンサス配列 (RepeatMaskerに使える)

RepeatMasker

- Input:
  - genome (FASTA)
  - データベース(custom/public)

```
$ RepeatMasker \
    -xsmall \
    -lib [NAME]-families.fa \
    genome.fasta
```

- Output
  - *.fasta.masked → ソフトマスク済みゲノム配列（以降の遺伝子予測に利用）
  - *.fasta.out → RepeatMasker の詳細結果（テキスト）
  - *.out.gff → リピート注釈のGFF出力
  - *.fasta.tbl → リピートの分類別サマリー（論文でも頻用される形式）

アノテーションのリフトオーバー（転用）

- 既存の高品質アノテーションの継承と転写
- リフトオーバー（Liftover）とは
  - 同種の別系統や、更新された新アセンブリに対し、既存の高品質な遺伝子モデルを「転写（移植）」する操作
  - 真核生物の新規遺伝子予測（de novo） は計算コストが高いため、信頼できるリファレンスがある場合に極めて有効
- 主な活用シーン
  - 同種の別系統への転用: 標準株（リファレンス）の情報を、解析対象の系統に移植
  - アセンブリのバージョンアップ: ゲノム配列を更新した際、旧バージョンのアノテーションを引き継ぐ
- Tool: liftoff

Liftoffの使い方

- Website: https://github.com/agshumate/Liftoff
- Inputs:
  - ターゲットゲノム: FASTA
  - リファレンスゲノム : FASATA
  - リファレンスアノテーション : GFF
- Usage

```
$ liftoff \
  -p 4 \
  -o CanAlb.liftover.gff3 \
  -dir liftoff_out \
  -g genomic.gff \  # reference annotation
  -copies \
  -sc 0.97 \
  -flank 0.2 \
  -d 4.0 \
  -polish \
  -u unmapped_features.txt \
  target_genome.fasta \
  reference_genome.fna \
```

構造アノテーションの評価

- Coding gene 遺伝子予測 : BUSCO
  - Protein mode or transcript mode
- RNA-seqとの比較
  - IGVによる可視化
  - gffcompare　による比較