

機能アノテーションと オーソログ解析

基礎生物学研究所
超階層生物学センター
データ統合解析室
内山 郁夫


ホモロジーに基づく
機能アノテーション

ゲノムアノテーション


- 遺伝子構造の予測
 - ゲノム中のどこに遺伝子(コード領域) があるかを、イントロン／エクソン構造を含めて予測する。
- 遺伝子機能の予測
 - 予測された遺伝子に対して、ホモロジー検索、もしくはモチーフ検索を行い、ヒットした類似配列もしくはモチーフの機能に基づいて機能を推定する。

ホモロジーに基づく機能推定

ホモロジー検索




モチーフ／プロファイル検索



ホモロジー（相同性）

共通祖先の同一の構造から派生した構造であること



相同性(homology)は類似性(similarity)に基づいて推定する

十分高い類似性がある → 相同性がある

```
ACGAGATATTG
|  |||  |||
GCCAGACATTA
```

BLAST (Basic Local Alignment Search Tool)

The screenshot shows the BLAST website interface. At the top, there's a navigation bar with links: Home, Recent Results, Saved Strategies, and Help. Below this, the main heading is "Basic Local Alignment Search Tool". A brief description states: "BLAST finds regions of similarity between biological sequences. The program compares nucleotide or protein sequences to sequence databases and calculates the statistical significance." A "Learn more" link is provided. To the right, a "NEWS" section dated "Mon, 21 Jul 2025" highlights a new release: "Download BLAST+ 2.17.0 now!" with a "More BLAST news..." link. The "Web BLAST" section features three main tools: "Nucleotide BLAST" (nucleotide > nucleotide), "blastx" (translated nucleotide > protein), and "tblastn" (protein > translated nucleotide). Below these is a "BLAST Genomes" section with a search bar for organism names and a "Search" button. The "Standalone and API BLAST" section offers three options: "Download BLAST", "Use BLAST API", and "Use BLAST in the cloud". The "Specialized searches" section includes eight tools: SmartBLAST, Primer-BLAST, Global Align, CD-search, IgBLAST, VecScreen, CDART, and Multiple Alignment, each with a brief description of its function.

program	query	database	translation
BLASTP	protein	protein	
BLASTN	nucleotide	nucleotide	
BLASTX	nucleotide	protein	query
TBLASTN	protein	nucleotide	database
TBLASTX	nucleotide	nucleotide	both

- 核酸配列は、相補鎖も同時に検索する
- 翻訳は、各鎖の3つの読み枠、計6通りの読み枠で比較する

<https://blast.ncbi.nlm.nih.gov/Blast.cgi>

ホモロジー検索とアノテーション

ヘモグロビン
β鎖

||
オーソログ

他の
グロビン族
(パラログ)

非相同
蛋白質

Sequences producing significant alignments:		Score	E
ue		(bits)	Val
ベストヒット		E-valueが低い	
sp:HBB_HUMAN	HEMOGLOBIN BETA CHAIN.	306	1e-83
sp:HBB_GORGO	HEMOGLOBIN BETA CHAIN.	305	3e-83
sp:HBB2_PANLE	HEMOGLOBIN BETA-2 CHAIN.	302	2e-82
sp:HBB_HYLLA	HEMOGLOBIN BETA CHAIN.	300	6e-82
sp:HBB_PREEN	HEMOGLOBIN BETA CHAIN.	298	4e-81
sp:HBB_COLPO	HEMOGLOBIN BETA CHAIN.	295	2e-80
sp:HBB_CERAE	HEMOGLOBIN BETA CHAIN.	295	3e-80
sp:HBB_MACFU	HEMOGLOBIN BETA CHAIN.	293	1e-79
sp:HBB_COLBA	HEMOGLOBIN BETA CHAIN.	293	1e-79
sp:MYG_BALAC	MYOGLOBIN.	49	5e-06
sp:MYG_MEGNO	MYOGLOBIN.	48	8e-06
sp:MYG_ESCGI	MYOGLOBIN.	48	1e-05
sp:MYG_BALPH	MYOGLOBIN.	47	2e-05
sp:MYG_ZIPCA	MYOGLOBIN.	46	4e-05
sp:GLB1_ARTSX	GLOBIN E1, EXTRACELLULAR.	45	9e-05
sp:GLP2_GLYDI	GLOBIN, POLYMERIC COMPONENT P2.	42	6e-04
sp:GLP1_GLYDI	GLOBIN, MAJOR POLYMERIC COMPONENT P1.	41	8e-04
sp:HBAZ_MACEU	HEMOGLOBIN ZETA CHAIN (FRAGMENTS).	39	0.005
sp:GLP3_GLYDI	GLOBIN, POLYMERIC COMPONENT P3.	38	0.009
sp:LGB2_PEA	LEGHEMOGLOBIN II.	36	0.035
sp:LGB1_PEA	LEGHEMOGLOBIN I.	35	0.079
sp:LGB2_SESRO	LEGHEMOGLOBIN 2.	34	0.18
sp:HBP_CANLI	LEGHEMOGLOBIN.	32	0.40
sp:LGB1_VICFA	LEGHEMOGLOBIN I.	32	0.53
sp:LACG_LACCA	6-PHOSPHO-BETA-GALACTOSIDASE (EC 3.2.1.85) (BETA-...	32	0.53
sp:LGB3_SESRO	LEGHEMOGLOBIN 3.	31	0.90
sp:LGBA_PHAVU	LEGHEMOGLOBIN A.	31	0.90
sp:HMPA_BACSU	FLAVOHEMOPROTEIN (HAEMOGLOBIN-LIKE PROTEIN) (FLAV...	31	1.2

E-value
非相同配列を
間違っ拾って
しまう個数の
期待値

統計的に
有意な類似性

微妙な類似性

統計的に
有意でない

コマンドライン BLAST

プログラム名 -query クエリ配列ファイル -db データベース名

プログラム名： blastp, blastn, tblastn, blastx, tblastx

- クエリ配列ファイルとして、ゲノム中の全遺伝子配列を含むファイルを指定することで、一度にすべての遺伝子に対する検索を実行できる。
- 複数クエリ配列に対する検索を行う場合、テーブル形式で出力する (-outfmt 6) とともに、出力数を制限するためのオプション (-max_target_seqs, -evalue) も指定するとよい。

```
% blastp -query all_proteins.fa -db swissprot -evalue 0.001  
-max_target_seqs 10 -num_threads 4 -outfmt 6 > blasttab
```

-max_target_seqs	上位いくつまで出力するか
-evalue	E-valueの閾値
-num_threads	CPUコアをいくつ使用するか

テーブル形式出力 (BLAST Tabular format)

		3. %identity	5. mismatch		7. q_start	9. s_start	11. eval				
1. query		2. subject (database)	4. align-len	6. gap_open	8. q_end	10. s_end	12. bit-score				
gi 4758884 ref NP_004553.1	O60260	99.785	465	1	0	1	465	1	465	0.0	964
gi 4758884 ref NP_004553.1	Q9JK66	84.946	465	70	0	1	465	1	465	0.0	830
gi 4758884 ref NP_004553.1	Q9WVS6	83.441	465	76	1	1	465	1	464	0.0	812
gi 4758884 ref NP_004553.1	Q7KTX7	42.194	474	241	8	1	463	30	481	7.05e-128	382
gi 4758884 ref NP_004553.1	E0VIU9	38.445	463	249	9	3	463	32	460	2.53e-113	344
gi 4758884 ref NP_004553.1	Q6T486	27.823	248	139	10	219	453	117	337	5.20e-14	77.8
gi 4758884 ref NP_004553.1	Q84RR0	29.004	231	125	10	231	453	130	329	9.49e-14	77.0
gi 4758884 ref NP_004553.1	Q6PFJ9	26.500	200	119	7	257	453	175	349	9.81e-12	70.5
gi 4758884 ref NP_004553.1	Q9Z1K5	26.500	200	119	7	257	453	203	377	1.01e-11	70.5
gi 4758884 ref NP_004553.1	A2VEA3	26.500	200	119	7	257	453	203	377	1.01e-11	70.5
gi 4758884 ref NP_004553.1	Q9Y4X5	26.500	200	119	7	257	453	205	379	1.07e-11	70.5
gi 4758884 ref NP_004553.1	Q94981	26.538	260	158	11	209	464	105	335	1.34e-11	70.1
gi 4758884 ref NP_004553.1	Q6NW85	26.500	200	119	7	257	453	181	355	1.35e-11	70.1
gi 4758884 ref NP_004553.1	B1H1E4	26.500	200	119	7	257	453	177	351	1.75e-11	69.7
gi 4758884 ref NP_004553.1	Q32NS4	26.066	211	126	8	257	464	177	360	4.50e-11	68.6
gi 4758884 ref NP_004553.1	Q8L829	27.826	230	127	10	232	453	126	324	1.33e-10	67.0
gi 4758884 ref NP_004553.1	Q9UBS8	28.319	226	129	8	256	464	239	448	3.33e-10	65.5
gi 4758884 ref NP_004553.1	Q9Z1K6	23.137	255	157	9	203	453	110	329	4.63e-10	65.1
gi 4758884 ref NP_004553.1	P0C8K8	28.017	232	129	11	230	453	125	326	7.87e-10	64.7
gi 4758884 ref NP_004553.1	O95376	24.016	254	156	9	203	453	111	330	7.95e-10	64.7
gi 4758884 ref NP_004553.1	Q9SKC3	26.786	224	124	10	235	449	125	317	1.90e-09	63.5
gi 4758884 ref NP_004553.1	Q9JI90	26.009	223	136	7	261	464	237	449	6.37e-09	61.6
gi 4758884 ref NP_004553.1	F1RB95	26.744	172	104	5	306	462	266	430	8.54e-09	61.2
gi 4758884 ref NP_004553.1	Q05120	33.333	72	48	0	1	72	1	72	1.27e-08	55.5

この出力形式は柔軟に変更できる。blastp -help を参照。

例えば、オプションを -outfmt "6 std stitle" とすると、上記の出力に加えて、13カラム目にデータベース配列のタイトル行を付加することができる。

ベストヒット配列の抽出

besthit.sh

```
#!/bin/bash  
file=$1  
awk 'prev != $1 {print; prev=$1}' $file
```

スクリプト besthit.sh の処理の内容：

スクリプトの第1引数から入力ファイル名をとり、それに対してawk コマンドを実行する。

awk コマンドの処理の内容：

prev は変数で、直前の行の1カラム目の値を保持する。初期値は空文字。

prevと現在の行の1カラム目の値(\$1)を比較し、異なる (!=) 場合にその行を出力し、prevを更新する。

prevと\$1が等しい場合は何もしないで次の行に進む。

```
% ./besthit.sh spo_sce.blast > spo_sce.blast.best
```

コマンドライン BLAST

データベースを自前で用意する

```
makeblastdb -in 配列ファイル -dbtype {prot|nucl} -out データベース名
```

- 例題：出芽酵母 *Saccharomyces cerevisiae* と(sce) 分裂酵母 *Schizosaccharomyces pombe* (spo) の遺伝子総当たり比較
- 配列ファイル sce.fa （出芽酵母全遺伝子の翻訳配列）にインデックスをつけ、sceという名前のデータベースを作る。

```
% makeblastdb -in sce.fa -dbtype prot -parse_seqids -out sce
```

- 作成したデータベースに対して、spo.fa（分裂酵母遺伝子の一部）をクエリとして、総当たりの検索を実行する。E-valueの閾値を0.001とし(-evalue)、クエリ当たり上位10個までのヒットを出力する(-max_target_seqs)。

```
% blastp -query spo.fa -db sce -num_threads 4  
-outfmt 6 -evalue 0.001 -max_target_seqs 6 > spo_sce.blast
```

DIAMOND 超高速ホモロジー検索

インデックスの作成

```
% diamond makedb --in db.fa --db db
```

検索の実行

```
% diamond blastp --query query.fa --db db
--evaluate 0.001 --max-target-seqs 10
--outfmt 6 qseqid sseqid pident eval evalue bitscore stitle
--threads 4 --out diamondout.tab
```

1. query	2. subject	3. %identity	4. evalue	5. bit-score	6. title
spo:NP_001018179.1	sce:NP_010076.1	40.8	5.77e-78	239	sce:NP_010076.1 hydroxymethylbilane synthase [Saccharomyces cerevisiae S288c]
spo:NP_001018181.1	sce:NP_014526.1	39.5	2.35e-74	248	sce:NP_014526.1 non-canonical poly(A) polymerase PAP2 [Saccharomyces cerevisi...
spo:NP_001018181.1	sce:NP_014100.2	38.0	1.36e-64	223	sce:NP_014100.2 non-canonical poly(A) polymerase TRF5 [Saccharomyces cerevisi...
spo:NP_001018187.2	sce:NP_013081.1	38.7	1.56e-87	288	sce:NP_013081.1 serine/threonine protein kinase KNS1 [Saccharomyces cerevisia...
spo:NP_001018187.2	sce:NP_012394.1	27.8	3.60e-39	152	sce:NP_012394.1 serine/threonine protein kinase YAK1 [Saccharomyces cerevisia...
spo:NP_001018187.2	sce:NP_013214.1	28.6	5.91e-33	130	sce:NP_013214.1 mitogen-activated protein kinase HOG1 [Saccharomyces cerevisi...
spo:NP_001018187.2	sce:NP_009537.1	28.8	3.68e-28	114	sce:NP_009537.1 mitogen-activated serine/threonine-protein kinase FUS3 [Sacch...
spo:NP_001018187.2	sce:NP_011554.3	24.8	1.29e-22	98.2	sce:NP_011554.3 mitogen-activated serine/threonine-protein kinase KSS1 [Sacc...
spo:NP_001018187.2	sce:NP_015294.1	23.2	6.08e-21	92.0	sce:NP_015294.1 cyclin-dependent serine/threonine-protein kinase PHO85 [Sacc...
spo:NP_001018193.1	sce:NP_012148.1	64.1	4.36e-92	267	sce:NP_012148.1 Rho family GTPase RHO3 [Saccharomyces cerevisiae S288c]


ベストヒット配列の抽出

Saccharomyces cerevisiae (sce) と *Schizosaccharomyces pombe* (spo) の総当たり比較から、クエリごとに最もスコアが高いヒットを抽出する。

spo:NP_001018179.1	sce:NP_010076.1	40.373	322	181	4	6	322	5	320	2.05e-81	248
spo:NP_001018181.1	sce:NP_014526.1	41.772	316	179	4	213	524	149	463	2.04e-80	265
spo:NP_001018181.1	sce:NP_014100.2	34.541	414	239	9	138	545	89	476	8.12e-72	243
spo:NP_001018187.2	sce:NP_013081.1	47.176	301	132	6	345	628	294	584	1.65e-88	290
spo:NP_001018187.2	sce:NP_013081.1	53.125	32	15	0	655	686	693	724	5.58e-04	41.2
spo:NP_001018187.2	sce:NP_012394.1	27.249	378	222	6	343	684	346	706	1.86e-41	159
spo:NP_001018187.2	sce:NP_013214.1	28.614	332	182	10	357	681	18	301	3.31e-31	125
spo:NP_001018187.2	sce:NP_014092.1	28.571	364	191	16	341	684	15	329	2.97e-30	120
spo:NP_001018187.2	sce:NP_009537.1	28.319	339	183	10	362	682	13	309	2.04e-27	112
spo:NP_001018187.2	sce:NP_011895.1	24.022	358	213	11	344	683	3	319	3.19e-24	104
spo:NP_001018191.1	sce:NP_011482.3	27.803	223	135	7	1	208	1	212	1.41e-12	62.4
spo:NP_001018193.1	sce:NP_012148.1	64.126	223	53	3	7	204	10	230	6.88e-98	281
spo:NP_001018193.1	sce:NP_015491.1	51.934	181	83	2	12	188	9	189	1.09e-61	189
spo:NP_001018193.1	sce:NP_014309.3	49.432	176	88	1	9	183	3	178	8.31e-54	168
spo:NP_001018193.1	sce:NP_012981.3	45.000	180	93	3	7	184	65	240	5.61e-48	156
spo:NP_001018193.1	sce:NP_013330.1	44.509	173	92	1	15	183	5	177	1.07e-46	150
spo:NP_001018193.1	sce:NP_014219.1	36.449	214	91	5	15	183	5	218	9.06e-33	118
spo:NP_001018195.1	sce:NP_011070.3	37.059	340	193	7	7	332	95	427	3.21e-62	202
spo:NP_001018195.1	sce:NP_011624.1	26.882	93	64	2	115	205	324	414	8.82e-04	38.9

BLAST 結果はクエリ毎にスコアの順に並んでいるので、1 カラム目のクエリ配列をチェックして、最初に出現した行のみを出力する。

双方向ベストヒットによるオーソログの推定



双方向ベストヒットの抽出

query	database											score	
sce:NP_011029.3	spo:NP_588421.1	78.362	647	135	1	1	642	1	647	0.0	1038	★	
sce:NP_012579.1	spo:NP_593459.1	70.570	649	184	3	11	653	27	674	0.0	944	★	
sce:NP_012500.3	spo:NP_593245.1	69.518	643	185	5	15	654	7	641	0.0	897	★	
sce:NP_014190.1	spo:NP_595438.1	69.657	613	183	3	1	612	1	611	0.0	852	★	
sce:NP_012500.3	spo:NP_588421.1	64.191	606	212	4	53	654	5	609	0.0	803		
sce:NP_011029.3	spo:NP_593245.1	61.741	609	226	6	4	609	37	641	0.0	763		
sce:NP_014190.1	spo:NP_588421.1	60.165	605	237	4	9	611	4	606	0.0	731		
sce:NP_011029.3	spo:NP_595438.1	62.630	578	215	1	4	580	8	585	0.0	702		
sce:NP_014190.1	spo:NP_593245.1	53.821	602	267	7	10	606	38	633	0.0	640		
sce:NP_012500.3	spo:NP_595438.1	55.952	588	251	4	47	626	3	590	0.0	634		
sce:NP_013473.1	spo:NP_593459.1	51.794	641	280	13	21	656	43	659	0.0	622		
sce:NP_012579.1	spo:NP_593245.1	50.403	621	286	10	25	632	30	641	0.0	569		
sce:NP_012579.1	spo:NP_588421.1	49.838	616	284	11	33	633	5	610	0.0	568		
sce:NP_011029.3	spo:NP_593459.1	48.366	612	298	10	5	609	53	653	0.0	562		
sce:NP_012500.3	spo:NP_593459.1	46.625	637	315	12	32	654	28	653	0.0	555		
sce:NP_014190.1	spo:NP_593459.1	47.928	555	268	9	10	557	53	593	2.07e-172	503		
sce:NP_013473.1	spo:NP_588421.1	47.920	553	257	12	29	570	3	535	1.05e-171	502		
sce:NP_013473.1	spo:NP_593245.1	45.971	546	273	7	30	570	37	565	4.95e-164	483		
sce:NP_012579.1	spo:NP_595438.1	45.894	621	311	12	26	631	2	612	4.53e-163	479		
sce:NP_013473.1	spo:NP_595438.1	43.134	568	285	11	31	583	9	553	4.42e-136	410		

まず総当たりの検索結果全体をスコアの順にソートして、スコアの高い方からクエリ、データベース両方の出現をチェックする。どちらも最初に出現した配列である場合、それが双方向ベストヒットとなる。

双方向ベストヒット配列の抽出

bbh.sh

```
#!/bin/bash
file=$1
sort -k 12,12nr $1 | ¥
    awk 'Rank1[$1]==0 && Rank2[$2]==0 {print} ¥
        {Rank1[$1]+=1; Rank2[$2]+=1}'
```

スクリプト bbh.sh の処理の内容：

スクリプトの第1引数から入力ファイル名をとり、そのファイルの12カラム目の値(=score) を数値データとして比較し大きい順にソートする。その結果に対して awk コマンドを実行する。

awk コマンドの処理の内容：



Rank1[\$1] と Rank2[\$2] は、連想配列(辞書) 変数で、それぞれ1カラム目(\$1; クエリ)、2カラム目(\$2; データベース) の配列名の登場回数を保持する。初期値は空文字(=0)。

Rank1[\$1] と Rank2[\$2] が0 である(初めて登場する) 行を出力する。

その後、各行において Rank1[\$1] と Rank2[\$2] の値を1つ増やす(+=1)。

```
% ./bbh.sh spo_sce.blast > spo_sce.blast.bbh
```


InterProScan モチーフ／ドメイン検索



InterProScan の実行

query.faをクエリとして、InterProのデータベース全てを対象として検索。
検索結果にはGO termも含める。

```
% interproscan.sh -i query.fa -b iprout -goterms --cpu 4
```

```
XM_018368617.1 b190671767a6618abe8a5898271389c4 298 Pfam PF01680 SOR/SNZ family 4 211 3.5E-103 ..
XM_018368617.1 b190671767a6618abe8a5898271389c4 298 ProSiteProfiles PS51129 PdxS/SNZ family profile. 6 298 150 ...
XM_018368617.1 b190671767a6618abe8a5898271389c4 298 Gene3D G3DSA:3.20.20.70 1 298 7.8E-137 ..
XM_018368617.1 b190671767a6618abe8a5898271389c4 298 TIGRFAM TIGR00343 TIGR00343: pyridoxal 5'-phosphate syntha..
XM_018368617.1 b190671767a6618abe8a5898271389c4 298 PIRSF PIRSF029271 1 298 1.9E-143 ..
```

検索結果からGO termの抽出

```
% cut -f1,14 outname.tsv
```

```
XM_018368617.1
XM_018368617.1 GO:0042819|GO:0042823
XM_018368617.1 GO:0003824
XM_018368617.1 GO:0042819|GO:0042823
XM_018368617.1 GO:0042819|GO:0042823
```

ホモロジーに基づくアノテーションの戦略


- 近縁種で、高品質なアノテーションがついたモデル生物ゲノムが利用可能な場合——そのゲノムに対するオーソログを同定し、アノテーションをコピーする。
- 特にターゲットとする生物種を絞らず、幅広い生物種から情報を集めたい場合——nrなどの網羅的なデータベースを検索して上位のヒットのアノテーションをコピーする。
- ホモロジー検索だけでは類似性が低い配列しかヒットせず、信頼性が低い場合——InterProなどのモチーフデータベースの検索を併用する。

オーソログ解析


ホモログの種類: オースログとパラログ

- ホモログ Homolog
 - 共通祖先の同じ遺伝子から派生した遺伝子
- オースログ Ortholog
 - 種分化により派生したホモログ
(e.g. hemoglobin β chains in human and mouse)
- パラログ Paralog
 - 遺伝子重複により派生したホモログ
(e.g. hemoglobin β chain and myoglobin)


オーソログとパラログ



Question: Ortholog or paralog?




Answer: Ortholog or paralog?




オーソログ解析と機能アノテーション

- 遺伝子の機能分化は、典型的には遺伝子重複のタイミングで生じる。その結果、オーソログは同じ機能を持つ傾向があるのに対し、パラログは異なる機能を持つ傾向にある。




オーソログ解析と種系統樹の推定

- 遺伝子系統樹に基づいて種の系統樹を推定するには、オーソログを用いる必要がある。



オーソロググループと比較ゲノム解析

- 多くの種のゲノムを比較する場合、それらの共通祖先種において同一の遺伝子であった遺伝子をまとめた「オーソロググループ（またはorthogroup）」を作成して比較する。



Species A	Species B	Species C
A1	B1	C1
A2	B2,B3,B4	C2,C3

1対1、1対多、多対多オーソログ

- 1対1オーソログ

- オーソログの対応づけが明確なので、種系統樹の作成や、種間比較の際のリファレンスとして有用。多数の種で1対1対応がつく遺伝子は、「ゲノム完成度」の指標としても有用（BUSCOなど）。

- 1対多オーソログ

- 特定の生物種において多様化が進んだ遺伝子。その生物種の特徴づけに有用

- 多対多オーソログ

- 種間で異なる多様化を遂げた遺伝子。一般に種間の正確な対応づけは難しいが、遺伝子ファミリーの進化として興味を持たれることも多い。


Species A	Species B	Species C
A1	B1	C1
A2	B2,B3,B4	C2,C3

1対1 オーソログ

1対多、多対多オーソログ


用語の整理：オーソログとオーソロググループ

- 遺伝子 C3 を中心に考える
 - C3の生物種Aにおけるオーソログ?
A2
 - C3の生物種Bにおけるオーソログ?
B3, B4
 - 生物種A, B, C を対象としたとき、C3
が含まれるオーソロググループ?
 $\{ \{A2\}, \{B2, B3, B4\}, \{C2, C3\} \}$
 - 生物種 B, C を対象としたとき、C3が
含まれるオーソロググループ?
 $\{ \{B3, B4\}, \{C3\} \}$



オーソログの推定方法


Tree-based method




1. 対象とする遺伝子の系統樹を作成する。
2. 系統樹内の各分岐点(内部ノード)に対して、「種分化」か「重複」のどちらが起こったかを推定する。
3. 種分化によって派生した遺伝子対がオーソログとなる。

「重複ノード」をどうやって推定するか？

Tree reconciliation vs species overlap




重複ノードの推定の実例





From SwissTree (<https://swisstree.sib.swiss/>)
NOX ancestral type

双方向ベストヒットによるオーソログの推定




Orthology is not always one-to-one relationship



Inparanoid


Add in-paralogs to each BBH pair




Candidate
orthologs by
BBH

Clustering


1) MERGE IF BOTH ORTHOLOGS ARE ALREADY CLUSTERED IN THE SAME GROUP




2) MERGE IF TWO EQUALLY GOOD BEST HITS FOUND





4) MERGE IF $(\text{SCORE}(A1-A2) < 0.5 * \text{SCORE}(A1-B1))$



5) DIVIDE IN-PARALOGS IN OVERLAPPING AREAS



3) DELETE WEAKER GROUP IF $(\text{SCORE}(A2-B2) - \text{SCORE}(A1-B1)) > 50$




Remm et al.
J. Mol. Biol., 2001

Orthology inference in multiple genomes

Graph-based method

Graph construction based on pairwise comparison




Clustering


- Triangle linkage (COG)
- Hierarchical clustering
- Markov clustering

Tree-based method


Phylogenetic tree construction



Grouping




Graph-based approach: OrthoMCL




Markov clustering (MCL)


original graph
(edges are weighted with probability)



Markov expansion
(expand the graph based on transitive probability)




inflation
(contrasting weights to make clusters)



Li et al., *Genome Res*, 2003


Hybrid approach: OrthoFinder

step1: graph-based method




Emms and Kelly, *Genome Biol.* 2015

step2: tree-based method



Emms and Kelly, *Genome Biol.* 2019

EggNOG Mapper オーソログベースのアノテーション



- あらかじめデータベース中の配列をオーソロググループに分類し、各グループの系統樹を作成。
- クエリ配列に対するホモロジー検索によりseed ortholog配列を同定し、さらに系統樹を用いて他生物種におけるオーソログを同定する。
- seed orthologに対する類縁関係を考慮し、近縁種のオーソログに付けられた機能アノテーションをコピーする。

EggNOG mapper の実行

DIAMONDを用いて、EggNOG mapperの実行

```
% emapper.py -i query.fa -o outname -m diamond --cpu 6
```

アノテーション結果から、テキスト記述を抽出

```
% cut -f1,8 outname.emapper.annotations
```

```
#query Description
XM_018368616.1 expression is induced before the diauxic shift and also in the absence of thiamin
XM_018368617.1 Belongs to the PdxS SNZ family
XM_018368618.1 member of a subtelomeric gene family including THI5 THI11 THI12 and THI13
XM_018368619.1 siderophore-bound iron prior to uptake by transporters
XM_018368620.1 involved in the retention of siderophore-iron in the cell wall
```

アノテーション結果から、アサインされたGOのリストを抽出

```
% cut -f1,10 outname.emapper.annotations
```

```
#query GOs
XM_018368616.1 GO:0003674,GO:0003824,GO:0004359,GO:0005575,GO:0005622,GO:0005623,GO:0005737,GO:0005829,GO:0006081,...
XM_018368617.1 GO:0000096,GO:0000097,GO:0003674,GO:0003824,GO:0003922,GO:0005575,GO:0005576,GO:0006082,GO:0006520,...
XM_018368618.1 GO:0003674,GO:0003824,GO:0006725,GO:0006766,GO:0006767,GO:0006772,GO:0006790,GO:0006807,GO:0008150,...
XM_018368619.1 GO:0000041,GO:0000293,GO:0000322,GO:0000323,GO:0000324,GO:0000329,GO:0003674,GO:0003824,GO:0005575,...
XM_018368620.1 GO:0000322,GO:0000323,GO:0000324,GO:0005575,GO:0005618,GO:0005622,GO:0005623,GO:0005737,GO:0005773,...
```

バージョン等によってカラム位置は違う可能性がある所以要確認