



Gene Ontology

基礎生物学研究所
超階層生物学センター
データ統合解析室
内山 郁夫

ファミリー／ドメインアノテーションの複雑さ




検索結果は各配列に一つではなく、ドメイン単位でつけられるもの、ドメインはオーバーラップしているが、ファミリーの大きさが異なるものなどが含まれる。

テキスト記述によるアノテーションの問題点


- 基本的に遺伝子（タンパク質）の名前を記載しただけで、具体的な機能について記載しているわけではない。
- 生物学的な解釈を考えるには、各遺伝子の機能に関する知識が別途必要になる。
- 大規模なゲノム解析結果を解釈するには、この部分についても計算機のサポートが必要。

Gene Ontology (GO)

機械可読な遺伝子機能の表現




包含関係を表すグラフ：有向非巡回グラフ Directed Acyclic Graph (DAG)



GO階層のグラフ

- 各ノードはGO termを表す
 - 最上位ノードは以下の3種類
 - biological process
 - molecular function
 - cellular component
- 各矢印（エッジ）はGO term間の関係を表す
 - 包含関係を表す矢印は2種類
 - is_a AはBの一種である
 - part_of AはBの一部である
 - その他の関係を表す矢印
 - regulates
 - occurs_in など



GO annotation

既知遺伝子へのGO termの割り当て


- GOアノテーションデータベース
 - モデル生物ゲノムデータベース
 - MGI (マウス)
 - FlyBase (ショウジョウバエ)
 - TAIR (シロイヌナズナ)
 - SGD (酵母) など
 - 網羅的なデータベース
 - タンパク質配列データベースUniProt
 - モチーフドメインデータベースInterPro
 - パスウェイデータベースReactome など
- アノテーションの根拠をEvidence Codeで示す

Human IKBKB gene に対するGO アノテーション

☐ Gene/product	Gene/product name	Annotation qualifier	GO class (direct)	Annotation extension	Contributor	Organism	Evidence	Evidence with	PANTHER family	Type	Isoform	Reference	Date
☐ IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		stimulatory C-type lectin receptor signaling pathway		Reactome	Homo sapiens	TAS		ikb kinase pthr22969	protein		Reactome:R-HSA-5621481	20181121
☐ IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		antigen processing and presentation of exogenous peptide antigen via MHC class I, TAP-dependent		Reactome	Homo sapiens	TAS		ikb kinase pthr22969	protein		Reactome:R-HSA-1236974	20180419
☐ IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		MyD88-independent toll-like receptor signaling pathway		Reactome	Homo sapiens	TAS		ikb kinase pthr22969	protein		Reactome:R-HSA-168927	20171201
☐ IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		protein kinase activity		UniProt	Homo sapiens	IDA		ikb kinase pthr22969	protein		PMID:20434986	20100804
☐ IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		protein serine/threonine kinase activity		UniProt	Homo sapiens	IDA		ikb kinase pthr22969	protein		PMID:15084260	20151001
☐ IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		protein serine/threonine kinase activity		Reactome	Homo sapiens	EXP		ikb kinase pthr22969	protein		PMID:18692471	20170505
☐ IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		protein serine/threonine kinase activity		Reactome	Homo sapiens	EXP		ikb kinase pthr22969	protein		PMID:23613522	20170505
☐ IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		protein serine/threonine kinase activity		UniProt	Homo sapiens	IDA		ikb kinase pthr22969	protein		PMID:25326416	20200702
☐ IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		protein serine/threonine kinase activity		CACAO	Homo sapiens	IDA		ikb kinase pthr22969	protein		PMID:25636800	20151001
☐ IKBKB	Inhibitor of nuclear factor kappa-B kinase subunit beta		protein serine/threonine kinase activity		Reactome	Homo sapiens	TAS		ikb kinase pthr22969	protein		Reactome:R-HSA-168140	20170811
☐ IKBKB	Inhibitor of nuclear factor kappa-B		protein serine/threonine kinase activity		Reactome	Homo sapiens	TAS		ikb kinase pthr22969	protein		Reactome:R-HSA-202541	20150207

Evidence Code

GO Evidence Code Decision Tree



- IEA (Inferred from Electronic Annotation) は計算機による予測のみなので要注意！
- ND (No Data)は、証拠がないことが確認されているので、さらに信頼性が低い


ホモロジーに基づくアノテーションの戦略（再掲）

- 近縁種で、高品質なアノテーションがついたモデル生物ゲノムが利用可能な場合——そのゲノムに対するオーソログを同定し、アノテーションをコピーする。
- 特にターゲットとする生物種を絞らず、幅広い生物種から情報を集めたい場合——nrなどの網羅的なデータベースを検索して上位のヒットのアノテーションをコピーする。
- ホモロジー検索だけでは類似性が低い配列しかヒットせず、信頼性が低い場合——InterProなどのモチーフデータベースの検索を併用する。

GOを用いてアノテーションする場合、GOアノテーションのついたデータベースを検索して、その結果に基づいてGO termをコピーすればよい。ただし、アノテーションのクオリティを考慮すると、2番めのケースは特に注意が必要。

ホモロジーに基づくGOアノテーション

Hit	Score	GO	Evidence
Gene-A	90	GO-2	IEA
Gene-B	85	GO-2	IDA
Gene-C	80	GO-3	IDA
Gene-D	60	GO-4	IEA



- 類似性検索でトップヒットのGOを採用すれば良いとは限らない。

→スコアが同程度なら、エビデンスコードを考慮して、より信頼性の高いアノテーションを採用した方がよい。

- あるGO termがアサインされる場合、その上位のGO termも必ずアサインされる。

→アノテーションとしては、その遺伝子に当てはまる最も下位のGO termを記載する。

BLAST2GO

- Annotation Score: $AS = DT + AT$
- $DT = \max(\text{similarity} \times ECw)$
ECw: Evidence Code weight
- $AT = (\#GO - 1) \times GOw$
#GO: number of child GOs assigned
GOw: GO weight (user defined parameter)
- $AS \geq \text{threshold}$ を満たす最下層のGOをアサインする

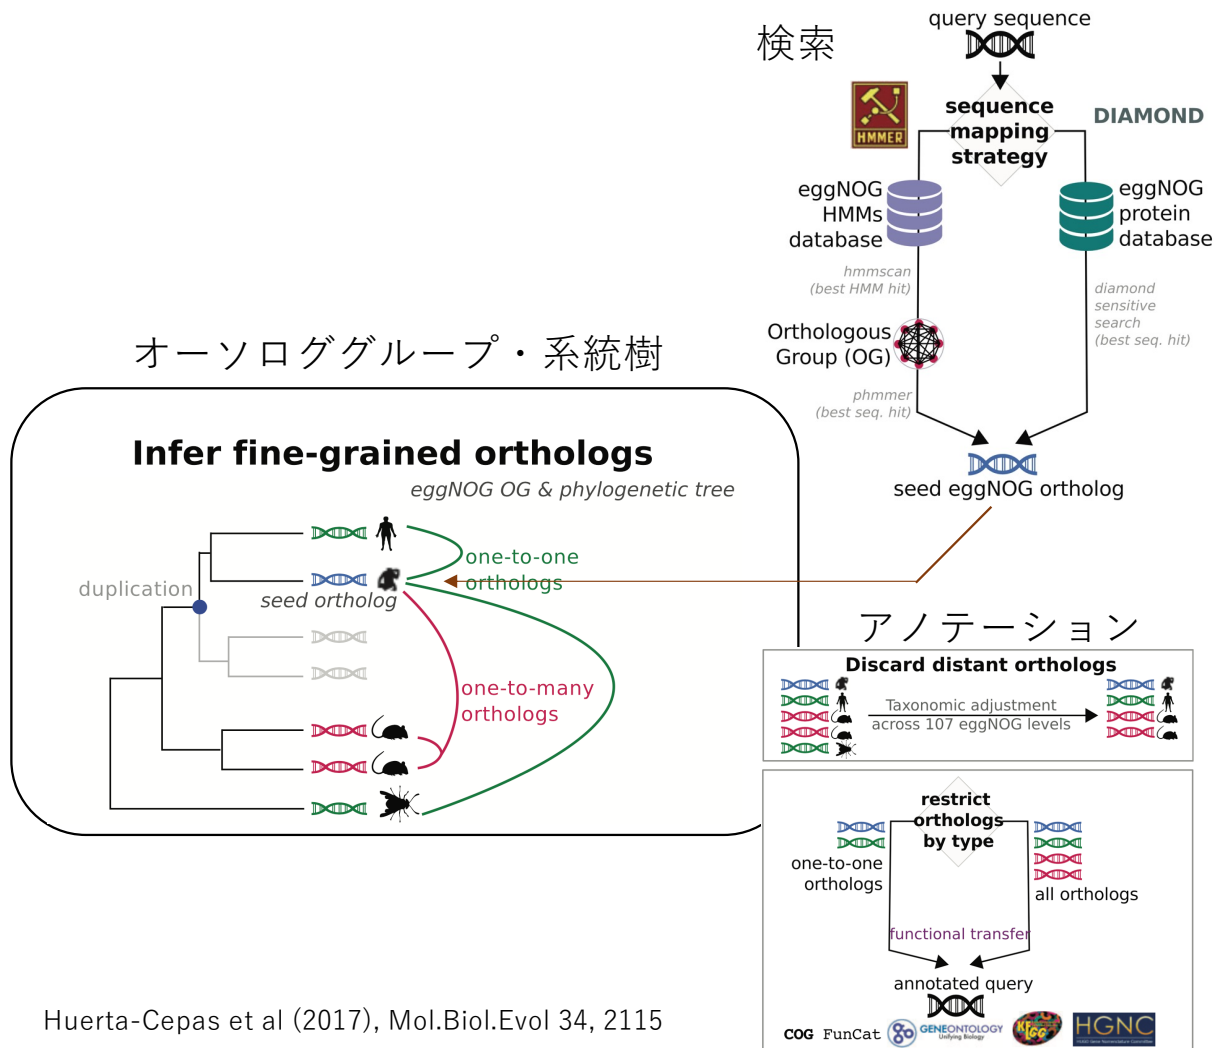
Evidence code weight

EC	Description	Default
IDA	Inferred from direct assay	1
IMP	Inferred from mutant phenotype	1
IGI	Inferred from genetic interaction	1
IPI	Inferred from physical interaction	1
IEP	Inferred from expression pattern	1
TAS	Traceable author statement	0.9
NAS	Non-traceable author statement	0.9
IC	Inferred by curator	0.9
ISS	Inferred from sequence or structural similarity	0.9
RCA	Inferred from reviewed computational analysis	0.9
IEA	Inferred from electronic annotation	0.7
ND	No biological data available	0.5
NR	Not recorded	0.5

Götz et al. (2008) Nucl.Acids.Res. 36, 3420

→OmixBoxという有償ソフトへ統合化

EggNOG Mapper オーソログベースのアノテーション




- あらかじめデータベース中の配列をオーソロググループに分類し、各グループの系統樹を作成。
- クエリ配列に対するホモロジー検索によりseed ortholog配列を同定し、さらに系統樹を用いて他生物種におけるオーソログを同定する。
- seed orthologに対する類縁関係を考慮し、近縁種のオーソログに付けられた機能アノテーションをコピーする。

Gene Ontologyを使った解析

- GO subset (GO slim) を使った集計
 - どのような機能の遺伝子がどのくらい含まれているか？
- GO enrichment 解析
 - どのような機能の遺伝子が特にエンリッチ(濃縮) しているか？

GO subset (GO slim)

- 複雑なGO階層全体の中から、有用な少数のGO termを抽出したもの。GOアノテーション結果の全体を上位階層で集約して集計したい場合などに使える。



GO subset

Download GO subsets

- The files available below for download are generated by script from that file.
- GO subsets are available in OBO, OWL as as well as JSON formats.

Subset name	Maintainer
Alliance of <i>Genome Resources</i> subset	Developed by GO Consortium for the Alliance of Genomes Resources
Generic GO subset	GO Consortium
<i>Aspergillus</i> subset	Aspergillus Genome Data
<i>Candida albicans</i> subset	Candida Genome Database
<i>Drosophila</i> subset	FlyBase
ChEMBL Drug Target subset	ChEMBL
Metagenomics subset	InterPro group
Mouse GO subset	Mouse Genome Informatics
Plant subset	The Arabidopsis Information Resource
Prokaryote subset	GO Consortium
Protein Information Resource subset	PIR
<i>Schizosaccharomyces pombe</i> subset	PomBase
Yeast subset	Saccharomyces Genome Database

<https://geneontology.org/docs/go-subset-guide/>


Generic GO subset

?x	?label
< http://purl.obolibrary.org/obo/GO_0000228 >	"nuclear chromosome"
< http://purl.obolibrary.org/obo/GO_0000278 >	"mitotic cell cycle"
< http://purl.obolibrary.org/obo/GO_0000910 >	"cytokinesis"
< http://purl.obolibrary.org/obo/GO_0001618 >	"virus receptor activity"
< http://purl.obolibrary.org/obo/GO_0002181 >	"cytoplasmic translation"
< http://purl.obolibrary.org/obo/GO_0002376 >	"immune system process"
< http://purl.obolibrary.org/obo/GO_0003012 >	"muscle system process"
< http://purl.obolibrary.org/obo/GO_0003013 >	"circulatory system process"
< http://purl.obolibrary.org/obo/GO_0003014 >	"renal system process"
< http://purl.obolibrary.org/obo/GO_0003016 >	"respiratory system process"
< http://purl.obolibrary.org/obo/GO_0003677 >	"DNA binding"
< http://purl.obolibrary.org/obo/GO_0003723 >	"RNA binding"
< http://purl.obolibrary.org/obo/GO_0003774 >	"cytoskeletal motor activity"
< http://purl.obolibrary.org/obo/GO_0003824 >	"catalytic activity"
< http://purl.obolibrary.org/obo/GO_0003924 >	"GTPase activity"
< http://purl.obolibrary.org/obo/GO_0005198 >	"structural molecule activity"
< http://purl.obolibrary.org/obo/GO_0005215 >	"transporter activity"
< http://purl.obolibrary.org/obo/GO_0005576 >	"extracellular region"
< http://purl.obolibrary.org/obo/GO_0005615 >	"extracellular space"
< http://purl.obolibrary.org/obo/GO_0005618 >	"cell wall"
< http://purl.obolibrary.org/obo/GO_0005634 >	"nucleus"
< http://purl.obolibrary.org/obo/GO_0005635 >	"nuclear envelope"
< http://purl.obolibrary.org/obo/GO_0005654 >	"nucleoplasm"
< http://purl.obolibrary.org/obo/GO_0005694 >	"chromosome"
< http://purl.obolibrary.org/obo/GO_0005730 >	"nucleolus"
< http://purl.obolibrary.org/obo/GO_0005739 >	"mitochondrion"
< http://purl.obolibrary.org/obo/GO_0005764 >	"lysosome"
< http://purl.obolibrary.org/obo/GO_0005768 >	"endosome"
< http://purl.obolibrary.org/obo/GO_0005773 >	"vacuole"
< http://purl.obolibrary.org/obo/GO_0005777 >	"peroxisome"
< http://purl.obolibrary.org/obo/GO_0005783 >	"endoplasmic reticulum"
< http://purl.obolibrary.org/obo/GO_0005794 >	"Golgi apparatus"
< http://purl.obolibrary.org/obo/GO_0005811 >	"lipid droplet"
< http://purl.obolibrary.org/obo/GO_0005815 >	"microtubule organizing center"
< http://purl.obolibrary.org/obo/GO_0005829 >	"cytosol"
< http://purl.obolibrary.org/obo/GO_0005840 >	"ribosome"
< http://purl.obolibrary.org/obo/GO_0005856 >	"cytoskeleton"
< http://purl.obolibrary.org/obo/GO_0005886 >	"plasma membrane"

RでのGO slimに基づく集計 (GSEABase)


```
# GO IDのリスト
> GO_ids <- c("GO:0016564", "GO:0003677", "GO:0004345", ...)
# generic GO slimの読み込み
> slim <- getOBOCollection("goslim_generic.obo")
# GO slimを使った集計 (BP=Biological Processに限定)
> slim.result <- goSlim(GOCollection(GO_ids), slim, "BP")
# 集計値を使って円グラフの作成
> c <- slim.result$Count
> names(c) <- slim.result$Term
> pie(c[c>0])
```


GO slim を使った集計



GO enrichment 解析

- 発現量が増加／減少した遺伝子群において、より多く出現する（エンリッチしている）機能(GO term)を抽出する。
- まず設定した閾値（有意水準）によって遺伝子セットを抽出し、その中でエンリッチメント解析を行うアプローチと、スコアの並び順を用いてエンリッチメント解析を行うアプローチがある。



Overrepresentation Analysis (Fisher's exact test)

一組のトランプから10枚のカードを抜き出したとき、赤札（ハート、ダイヤ）が5枚、絵札（JQK）が4枚含まれていた。このとき、赤札と絵札のどちらがよりエンリッチ（濃縮）していると言えるか？

2♠ 3♣ 5♠ 6♥ 6♦ 8♠ J♦ Q♦ Q♣ K♦

赤札 5枚
全体 $26/52 = 0.5$
手札 $5/10 = 0.5$

$p=0.6368$

絵札 4枚
全体 $12/52 = 0.23$
手札 $4/10 = 0.4$

$p=0.2492$

ダイヤの絵札 3枚
全体 $3/52 = 0.058$
手札 $3/10 = 0.3$

$p=0.00543$

分割表

	絵札	数札	計
手札	4	6	10
残り	8	34	42
計	12	40	52

Fisher's exact test (正確確率検定)

N枚のカード中にn枚の「当たり」が含まれるとき、そこからm枚を抜き出した中に「当たり」がk枚以上(または以下)含まれる確率を求める。

→超幾何分布(Hypergeometric distribution)
で計算できる

$$P(k;n,m,N) = \frac{\binom{n}{k} \binom{N-n}{m-k}}{\binom{N}{m}}$$


Rでの計算

```
> tab <- matrix( c(4,8,6,34), 2, 2 )  
> fisher.test(tab,  
               alternative='greater')
```

Overrepresentation Analysis (Fisher's exact test)

発現上昇した遺伝子セット800個のうち、60個にあるGO termが付けられていた。ゲノム全体10000遺伝子のなかで、そのGO termが付けられた遺伝子は500個であった。このGO termは発現上昇した遺伝子セット中で過剰出現していると言えるか？

発現上昇した遺伝子数が1000個であった場合はどうか？



分割表

	機能を持つ	機能を持たない	計
発現上昇あり	60	740	800
発現上昇なし	440	8760	9200
計	500	9500	10000

→ Fisherの正確確率検定 (Fisher's exact test)

```
fisher.test( matrix( c(60, 440, 740, 8760), 2, 2), alternative='greater' )
```

p=0.00089


(発現上昇した遺伝子が1000個の場合)

```
fisher.test( matrix( c(60, 440, 940, 8560), 2, 2), alternative='greater' )
```


p=0.076

結果が発現差
解析の閾値に
依存


Gene Set Enrichment Analysis (GSEA)



- 全遺伝子を発現解析の結果に基づいてソートし、その並び順の中で、対象とする遺伝子セットの出現が、偏りのない分布（一様分布）からずれているかを判定する（Kolmogorov-Smirnov検定）。
- カウントを、ソートに用いた指標で重み付けすることにより、上位/下位のヒットにより大きな重みを与えることもできる。



GO enrichment 解析とGO階層



- GO enrichment解析では、全てのGO termについてenrichment testを繰り返す。
- GO階層の下位ノードにアサインされた遺伝子は上位ノードにも自動的にアサインされるため、上下ノードに依存関係が生じる。


→有意なGO termは、GO階層上近傍に集まって出現することが多い。

→上位ノードは分母が大きくなるため、「濃縮度」は低くなる。

Rを用いたGO enrichment 解析

- clusterProfiler

- GOのほか、KEGGやDisease Ontology(DO)など、様々なデータベースに対応
- 結果を可視化するツールが充実している



clusterProfilerによる解析

Fisher's exact testの実行: **enrichGO**


入力：対象遺伝子 `targetGenes`, 全体遺伝子 `allGenes`, アノテーションDB `org.Mm.eg.db`

Biological Process (BP)を対象として実施。遺伝子の検索キーはENSEMBL


```
> cprof.up.bp.fisher <- enrichGO(gene=upregGenes, universe=allGenes,  
                                OrgDb=org.Mm.eg.db, ont="BP", keyType="ENSEMBL",  
                                pvalueCutoff=0.01)
```


解析結果の可視化(Fisher's exact test)

```
> library(enrichplot)
> barplot(cprof.up.bp.fisher, showCategory=10)
```




```
> goplot(cprof.up.bp.fisher, showCategory=10)
```




解析結果の可視化(Fisher's exact test)

```
# org.Mm.eg.db データベースを使って、 ENSEMBL IDから可読性の高い名前に変換する
> cprof.up.bp.fisher <-setReadable(cprof.up.bp.fisher, 'org.Mm.eg.db', "ENSEMBL")
> cnetplot(cprof.up.bp.fisher)
```





```
> upsetplot(cprof.up.bp.fisher)
```



解析結果の可視化(Gene Set Enrichment Analysis)

```
> ridgeplot(cprof.bp.gsea)  
> gseaplot(cprof.bp.gsea, geneSetID=1)
```


>



ユーザアノテーションの利用 1

オーソログ解析に基づくアノテーション

- 近縁のモデル生物の遺伝子に対するオーソログ対応づけができている場合、それによってモデル生物のアノテーションを対応づけてGO解析を行うことができる。



ユーザノテーションの利用 2

遺伝子-GO対応表の取り込み

- 遺伝子ごとのGO termのアサインができている場合、それを直接読み込んで解析する。
- clusterProfilerでは、以下のいずれかの形式で遺伝子とGOの対応表を準備する。

GMT 形式

GO-1	GOname1	gene1	gene2	gene3
GO-2	GOname2	gene4	gene5	

`read.gmt(gmfile)` で読み込む。
GOnameを読み飛ばして、右の形式と同じ
データフレームを生成する。

または、以下の形式

GO-1	gene1
GO-1	gene2
GO-1	gene3
GO-2	gene4
GO-2	gene5

`read.delim(file)` で読み込む

- clusterProfilerでは、GO ID とその名前の対応表(TERM2NAME)も用意する必要がある。

GO-1	GOname1
GO-2	GOname2

clusterProfilerによる解析(対応表を読み込む)

遺伝子とGOID対応表の読み込み

```
> go2gene <- read.gmt("go2gene.gmt")
```

祖先ノードに遡ってGOをアサインする

```
> go2gene.expand <- biuldGMap(go2gene)
```

TERM2NAMEの対応表をGO.dbから作成する

```
> gonames <- select(GO.db, keys=keys(GO.db), columns="TERM")
```

Fisher's exact testの実施 (enricher)

```
> cprof.fisher2 <- enricher(gene=upregGenes, TERM2GENE=go2gene.expand,  
                             TERM2NAME=gonames)
```

入力データの準備

```
# edgeRのデータオブジェクト (DGEList) から解析結果全体をテーブルとして抜き出す  
etab <- topTags(DGEList, n=999999)$table
```

```
## Fisher's exact testの入力： 発現変動遺伝子のリストと全遺伝子のリスト  
# FDRが0.01以下で、かつ2倍以上 ( $\log FC > 1$ ) 発現上昇した遺伝子を抽出  
upreg <- subset(etab, logFC > 1.0 & etab$FDR < 0.01)  
# 発現上昇した遺伝子と全遺伝子の遺伝子名リストをそれぞれ作成  
upregGenes <- rownames(upreg)  
allGenes <- rownames(etab)
```

GOアノテーションの準備

公開されたアノテーションデータベースの利用1

OrgDb

- 代表的モデル生物種の遺伝子データベースでGOのアノテーションを含む。
- org.<Sp>.<id>.db という名称のパッケージとして公開。ヒトorg.Hs.eg.db、マウスorg.Mm.eg.dbなど、<id>=eg (Entrez Gene)のものを中心に現在約20種類。
- enrichment解析に用いるには、遺伝子IDが、NCBI GeneIDなど、このデータベースに登録されたIDのいずれかと一致する必要がある。
- AnnotationDbiパッケージのselect関数で検索する。キー（遺伝子ID）とカラム(抽出する遺伝子属性)を指定して情報を取り出す。

```
> library(org.Mm.eg.db)
# マウス用データベース。ロードすると、org.Mm.eg.db という名前のオブジェクトを介してデータベースにアクセスできる
# 利用可能な属性の一覧を表示
> columns(org.Mm.eg.db)
[1] "ACCNUM"      "ALIAS"       "ENSEMBL"     "ENSEMBLPROT" "ENSEMBLTRANS"
[6] "ENTREZID"    "ENZYME"      "EVIDENCE"    "EVIDENCEALL"  "GENENAME"
[11] "GO"         "GOALL"       "IPI"         "MGI"          "ONTOLOGY"
[16] "ONTOLOGYALL" "PATH"        "PFAM"        "PMID"         "PROSITE"
[21] "REFSEQ"      "SYMBOL"      "UNIGENE"     "UNIPROT"
# SYMBOLが "KRAS" である遺伝子のGOを表示
> select(org.Mm.eg.db, keys="Kras", keytype="SYMBOL", columns="GO")
  SYMBOL      GO EVIDENCE ONTOLOGY
1   Kras GO:0000166      IEA      MF
2   Kras GO:0001934      ISO      BP
3   Kras GO:0003924      IGI      MF
```


GOアノテーションの準備

公開されたアノテーションデータベースの利用2

AnnotationHub

- より多くの生物種のアノテーションを集積。必要なものをダウンロードして使う。“OrgDb”として登録されたものは前項のOrgDbデータベースと同様に使える。

```
> library(AnnotationHub)
# AnnotationHubへのアクセスインターフェイスを変数ahに格納
> ah <- AnnotationHub()
# イネ(Oryza sativa)を検索。Queryコマンドの2番目の引数は、任意の数のキーワードをベクトルとして与える。
> query(ah, c("OrgDb", "oryza sativa"))
AnnotationHub with 3 records # <- ヒットが3つ見つかった
# snapshotDate(): 2022-04-25
...
# retrieve records with, e.g., 'object[["AH101066"]]' # <- データへのアクセス方法。objectは変数名ahに置き換える
      title                                     # 以下、ヒットしたデータの一覧
AH101066 | org.Oryza_sativa_(japonica_cultivar-group).eg.sqlite
AH101067 | org.Oryza_sativa_Japonica_Group.eg.sqlite
AH101068 | org.Oryza_sativa_subsp._japonica.eg.sqlite
# データをダウンロードし、org.os.dbという変数に格納
> org.os.db <- ah[["AH85565"]]
> columns(org.os.db)
"ACCNUM"  "ALIAS"  "CHR"      "ENTREZID"  "EVIDENCE"  "EVIDENCEALL"  "GENENAME"  "GID"      "GO"
"GOALL"   "ONTOLOGY"  "ONTOLOGYALL"  "PMID"      "REFSEQ"    "SYMBOL"
```